Đánh giá thực nghiệm các mô hình sinh truyện ngụ ngôn theo yêu cầu

So sánh năm hệ thống được xây dựng độc lập trên cùng một quy trình đánh giá

Nhóm 16 — IT5410

20252611M — Lê Hải Triều
20252612M — Đào Đức Tùng
20252610M — Nguyễn Công Thanh
20252130M — Nguyễn Thị Phương Liên
20252737M — Nguyễn Đình Lê Hoàng

2026-07-26

Mục lục

Tóm tắt **26**

1. Giới thiệu **4**

1.1 Mục tiêu và câu hỏi nghiên cứu 4

1.2 Tác vụ và dữ liệu 4

1.3 Các chỉ số đánh giá 4

1.4 Thiết kế đánh giá 5

2. Dữ liệu và phương pháp **5**

2.1 Tổng quan về bằng chứng thực nghiệm 5

2.2 E1 — Llama 30M/60M huấn luyện từ đầu — Lê Hải Triều (20252611M) 8

2.3 E2 — GPT 63M huấn luyện từ đầu — Đào Đức Tùng (20252612M) 16

2.4 E3 — So sánh vị trí LoRA trên SmolLM2-135M — Nguyễn Công Thanh (20252610M) 23

2.5 E4 — Llama 3.2 3B với kiểm soát đầu ra — Nguyễn Thị Phương Liên (20252130M) 26

2.6 E5 — QLoRA và lượng tử hóa Llama 3.2 3B — Nguyễn Đình Lê Hoàng (20252737M) 29

2.7 Phân tích định tính các đầu ra 31

3. Kết quả theo câu hỏi nghiên cứu **32**

3.1 RQ1 — Ảnh hưởng của năng lực nền 32

3.2 RQ2a — Ảnh hưởng của dữ liệu và tối ưu hóa 32

3.3 RQ2b — Vị trí đặt các tham số thích nghi 33

3.4 RQ4 — Đóng góp của lớp kiểm soát khi suy luận 33

3.5 Khả năng so sánh giữa các đánh giá nội bộ 33

4. Đánh giá chung và các thí nghiệm phân tích **33**

4.1 Thiết lập và trạng thái thực nghiệm 33

4.2 Tệp mô hình và môi trường chạy 34

4.3 Bộ đề đánh giá 34

4.4 Quy trình sinh 34

4.5 Làm mù và hàm chấm điểm 35

4.6 Kết quả định lượng 35

4.7 Phân tích trường hợp GJ20 36

4.8 Phân tích kết quả 37

4.9 Thí nghiệm phân tích không huấn luyện lại 37

5. Thảo luận **39**

5.1 Tổng hợp các phát hiện 39

5.2 Hàm ý cho việc lựa chọn hệ thống 40

5.3 Các yếu tố đe dọa tính hợp lệ 40

6. Kết luận **40**

7. Khả năng tái lập và đóng góp của các thành viên **41**

7.1 Phân công thực hiện thí nghiệm 41

7.2 Tệp mô hình và khả năng tái lập 41

Tài liệu tham khảo **42**

Tóm tắt

Mục tiêu. Nghiên cứu đánh giá các cách xây dựng hệ thống sinh truyện ngụ ngôn tiếng Anh có điều kiện theo năm trường và có thể chạy cục bộ: nhân vật, bối cảnh, thử thách, kết quả và bài học đạo đức.

Phương pháp. Nghiên cứu khảo sát ba nhóm phương pháp: (i) tiền huấn luyện mô hình từ trạng thái khởi tạo ngẫu nhiên; (ii) PEFT/QLoRA trên mô hình đã tiền huấn luyện; và (iii) kiểm soát đầu ra bằng kiểm tra tính hợp lệ, hậu xử lý và sửa lỗi theo điều kiện. Trong từng hướng, kết quả đánh giá nội bộ chỉ dùng để chọn cấu hình đại diện; không dùng để so sánh giữa các hướng vì tập đề và giám khảo khác nhau. Năm hệ thống đại diện sau đó được chạy trên cùng 25 đề, tạo ra 125 truyện và được chấm mù bằng `gemma-4-26b-a4b-it`. Ba thí nghiệm loại trừ, không huấn luyện lại, đo độ phủ điều kiện, **counterfactual sensitivity** (mức độ đầu ra thay đổi đúng hướng khi chỉ thay đổi một điều kiện) và đóng góp của bước sửa lỗi.

Kết quả baseline v1. Quy trình đánh giá chung ban đầu cho thấy hai nhóm kết quả rõ rệt: E4 đạt 9,20/10 và E5 đạt 8,44/10, trong khi E1–E3 nằm trong khoảng 2,81–3,30. Tuy nhiên, chênh lệch điểm tổng hợp không thể quy trực tiếp cho số tham số, vì năm hệ thống còn khác nhau ở dữ liệu tiền huấn luyện, giao diện điều kiện, kỹ thuật tinh chỉnh và hậu xử lý. Các thí nghiệm loại trừ cho thấy nguyên nhân cụ thể hơn. Khi tăng số trường đầu vào từ hai lên năm, E5 tăng độ phủ lên 3,68/5 và điểm nhất quán với chuỗi sự kiện được yêu cầu lên 7,28/10. E1 chỉ tăng độ phủ 0,44/5 và vẫn ở gần mức sàn; điểm nhất quán nội tại gần như không đổi. Điều này cho thấy mô hình có thể tạo ra một câu chuyện tự thân hợp lý nhưng không thực sự dùng đề bài. Trong 10 cặp counterfactual, E5 điều chỉnh lựa chọn hoặc cách giải quyết phù hợp với thay đổi về tính cách hay kết quả ở cả 10 cặp, so với 1/10 của E1. Với E4, repair đưa tỷ lệ bài học đúng nguyên văn từ 20% lên 100% và tăng điểm nhất quán theo yêu cầu từ 9,00 lên 9,64, nhưng không làm thay đổi hai liên kết trait→choice (92%) và choice→outcome (100%). Như vậy, mối quan hệ giữa điều kiện và diễn biến đã có trong đầu ra thô; repair chủ yếu sửa định dạng đầu ra và các sai lệch cục bộ.

Cập nhật giao thức v2 (14/08/2026). Sau khi phát hiện runner v1 bỏ token mở truyện `<|story|>` của E1 và bỏ `system_message` của E3, nhóm đã sửa hai runner và sinh lại đủ 25/25 đầu ra cho cả năm hệ. Lượt chấm Google v2 được ưu tiên cho hai hệ bị ảnh hưởng: E1 đạt **4,60/10** (95% CI **[4,38; 4,83]**) và E3 đạt **3,13/10** (95% CI **[2,95; 3,31]**), đều đủ 25/25 truyện. Ba hệ còn lại đã có đầu ra v2 nhưng lượt chấm đang dừng ở quota Google, nên các số v1 bên dưới được giữ làm baseline và không trộn với hai số v2 thành một bảng xếp hạng mới. Giao thức v2 cũng không thưởng hay phạt việc xuất hiện nguyên văn dòng `Moral:`; vì vậy không nên so sánh cơ học các điểm v2 với điểm nội bộ 8,96 và 6,87 vốn dùng prompt, judge và quy trình khác.

Kết luận. Đóng góp chính của nghiên cứu không phải là kết luận đơn giản rằng mô hình lớn hơn sẽ đạt điểm cao hơn. Quan trọng hơn, nghiên cứu phân biệt ba mức độ tuân thủ: nhắc lại trường đầu vào, tổ chức diễn biến phù hợp với toàn bộ điều kiện, và thay đổi diễn biến đúng hướng khi một điều kiện bị can thiệp. Độ trôi chảy, loss và tính hợp lý nội tại chỉ đo chất lượng bề mặt, không thể thay thế ba phép kiểm tra này. Trong phạm vi thí nghiệm, E5 cung cấp bằng chứng mạnh nhất về khả năng kết hợp các điều kiện ngay trong một lượt sinh; E4 cho thấy validator/repair có thể tăng độ tin cậy của đầu ra khi nội dung gốc đã đúng về mặt ngữ nghĩa. Hai kết quả này dẫn đến hai ưu tiên thiết kế khác nhau: nếu truyện chưa dùng điều kiện để chi phối diễn biến, cần cải thiện mô hình, dữ liệu hoặc mục tiêu huấn luyện theo điều kiện; nếu diễn biến đã đúng nhưng định dạng và bài học chưa ổn định, repair là lớp kiểm soát phù hợp. Kết luận này chỉ áp dụng cho tập kiểm thử hiện tại và chưa cho phép suy ra một ngưỡng số tham số áp dụng rộng rãi cho năng lực suy luận nhân quả.

1. Giới thiệu

1.1 Mục tiêu và câu hỏi nghiên cứu

Mục tiêu của nghiên cứu là xác định biện pháp can thiệp nào cải thiện chất lượng và mức độ tuân thủ điều kiện của mô hình sinh truyện ngụ ngôn khi tài nguyên huấn luyện và suy luận bị giới hạn. Bốn câu hỏi nghiên cứu được đặt ra:

- **RQ1 — Năng lực nền:** tiền huấn luyện từ đầu ở quy mô 60M–63M khác với việc dùng mô hình đã tiền huấn luyện 135M–3B như thế nào về độ trôi chảy và tuân thủ điều kiện?
- **RQ2 — Can thiệp huấn luyện:** ngân sách token, phân bố dữ liệu, vị trí LoRA và số chu kỳ huấn luyện ảnh hưởng như thế nào đến chất lượng đầu ra?
- **RQ3 — Sử dụng điều kiện:** mô hình có dùng điều kiện để thay đổi diễn biến hay chỉ tái tạo từ khóa và mô-típ quen thuộc?
- **RQ4 — Kiểm soát khi suy luận:** validation, chuẩn hóa định dạng và rewrite đóng góp ở mức nào so với năng lực của checkpoint gốc?

E1–E5 đại diện cho năm thiết kế thực nghiệm với các biến can thiệp khác nhau. Kết luận nhân quả chỉ được rút ra từ các thí nghiệm loại trừ trong từng hướng, với biến can thiệp được kiểm soát. Quy trình đánh giá chung ở Mục 4 đo hiệu năng toàn hệ thống; vì không đồng thời kiểm soát kiến trúc, dữ liệu, quy mô và hậu xử lý, kết quả này không thể dùng để quy chênh lệch cho một yếu tố riêng lẻ.

1.2 Tác vụ và dữ liệu

Nguồn dữ liệu chính là `klusai/ds-tf1-en-3m` (TF1-EN-3M), một bộ truyện ngụ ngôn tổng hợp gồm đề bài có cấu trúc và phần nội dung tương ứng. Nghiên cứu sử dụng hai dạng đầu vào có điều kiện:

- E2 sử dụng `Nhân vật` và `Bài học`, phù hợp với định dạng huấn luyện của V16;
- E1, E3, E4 và E5 sử dụng năm trường `Nhân vật`, `Bối cảnh`, `Thử thách`, `Kết quả` và `Bài học`.

Hạ tầng dùng chung gồm FastAPI, React và lớp phục vụ Ollama/MLX; hỗ trợ truyền kết quả theo thời gian thực và chế độ so sánh. Mỗi hướng có một hệ thống đại diện, được đăng ký như một backend riêng để kiểm tra khả năng vận hành trước khi đưa vào đánh giá.

1.3 Các chỉ số đánh giá

Bốn khía cạnh chính của đầu ra được theo dõi như sau:

Khía cạnh	Câu hỏi
Ngôn ngữ	Truyện có đúng ngữ pháp, mạch lạc và dễ đọc với trẻ em?
Nội dung	Truyện có sáng tạo nhưng vẫn giữ cấu trúc ngụ ngôn?
Bài học	Bài học đạo đức có rõ ràng, phù hợp với diễn biến và đầy đủ không?
Điều kiện	Các điều kiện đầu vào có thực sự chi phối câu chuyện không?

Các thước đo tự động dưới đây được dùng để đánh giá chất lượng bề mặt:

Thước đo	Cách tính và ý nghĩa	Hướng mong muốn	Lưu ý
Distinct-1	Số unigram khác nhau chia cho tổng số unigram trong tập truyện; đo độ đa dạng từ vựng	cao hơn	Văn bản ngẫu nhiên hoặc kém mạch lạc cũng có thể đạt điểm cao

Thước đo	Cách tính và ý nghĩa	Hướng mong muốn	Lưu ý
Distinct-2	Số bigram khác nhau chia cho tổng số bigram; nhạy hơn với việc lặp cụm từ	cao hơn	Phụ thuộc tokenizer, cỡ mẫu và độ dài truyện
Self-BLEU	Mức chồng lặp n-gram trung bình giữa các truyện do cùng hệ thống sinh; đo độ giống nhau trong tập đầu ra	thấp hơn	Điểm thấp không đồng nghĩa truyện hay; nhiễu cũng có thể làm điểm thấp
Flesch Reading Ease	`206,835 − 1,015·(từ/câu) − 84,6·(âm tiết/từ)`; ước lượng độ dễ đọc của tiếng Anh	cao hơn; khoảng 80–100 thường được xem là dễ đọc với trẻ em	Không đo logic, nội dung hay độ đúng của bài học

Trong triển khai E1, Distinct được tính trên các token được tách theo khoảng trắng; Self-BLEU là độ chính xác 4-gram trung bình trên mọi cặp truyện; Flesch được tính cho từng truyện rồi lấy trung bình. Vì các giá trị phụ thuộc cách tách token, cỡ mẫu và cách tính BLEU, chúng chỉ nên được so sánh trong cùng một quy trình đánh giá. Tỷ lệ khớp các trường và tỷ lệ có dòng bài học đo mức độ đúng định dạng đầu ra, không thay thế cho việc đánh giá quan hệ nhân quả. Điểm do LLM chấm cũng chỉ nên được so sánh khi giữ cố định giám khảo, thang điểm, đề bài, cấu hình lấy mẫu và cỡ mẫu.

1.4 Thiết kế đánh giá

Nghiên cứu sử dụng hai lớp đánh giá. **Đánh giá nội bộ** so sánh các biến thể trong cùng một hướng tiếp cận theo quy trình của thành viên phụ trách; các điểm này không được dùng để xếp hạng E1–E5 vì khác tập đề, giám khảo và thang đo.

Đánh giá chung chạy hệ thống đại diện của mỗi hướng trên cùng 25 đề để tạo đầu ra mới, cố định seed và cấu hình giải mã, ẩn danh mô hình trước khi chấm bằng cùng một giám khảo Gemma. Thiết kế này cho phép so sánh trực tiếp ở cấp hệ thống, nhưng không khiến năm hướng trở thành một thí nghiệm đối chứng hoàn toàn tương đương; đồng thời, ảnh hưởng của kích thước mô hình và chi phí suy luận vẫn chưa được cô lập hoàn toàn.

2. Dữ liệu và phương pháp

Hướng tiếp cận	Mô hình nền	Biến can thiệp/chủ đề chính	Hệ thống đại diện
E1 · Lê Hải Triều (20252611M)	khởi tạo ngẫu nhiên; thiết kế kiểu Llama 30M/60M	ngân sách token, thay đổi dữ liệu, hậu huấn luyện, tăng quy mô	`slm-60m`
E2 · Đào Đức Tùng (20252612M)	khởi tạo ngẫu nhiên; thiết kế kiểu GPT 63M	tokenizer, tiền huấn luyện, điều kiện đầu vào có cấu trúc	`v16-conditioned`
E3 · Nguyễn Công Thanh (20252610M)	SmolLM2-135M	vị trí đặt LoRA theo tầng/mô-đun	`tsv3-smollm135-best`
E4 · Nguyễn Thị Phương Liên (20252130M)	Llama 3.2 3B Instruct	so sánh SFT/LoRA với tăng cường đề bài, hậu xử lý và repair	Base + Repair
E5 · Nguyễn Đình Lê Hoàng (20252737M)	Llama 3.2 3B Instruct	so sánh QLoRA qua 1 và 3 chu kỳ, GGUF Q4	`llama3-fable-1000-q4`

2.1 Tổng quan về bằng chứng thực nghiệm

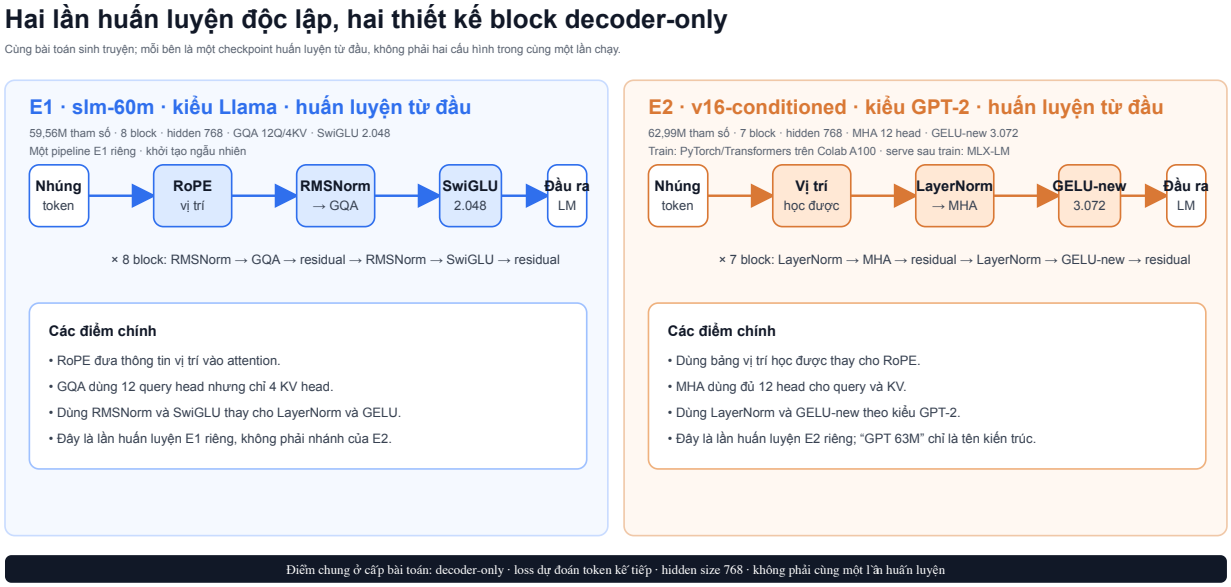
Mức độ lưu trữ artifact giữa các hướng không giống nhau. Bảng dưới phân biệt số liệu từ các lần chạy thực tế với thông tin chỉ có trong mô tả cấu hình:

Cấu hình	Dữ liệu và cách chia	Cấu hình huấn luyện	Đầu ra do mô hình sinh
E1 · Lê Hải Triều (20252611M)	có nhật ký xây dựng corpus	có script và nhật ký	mẫu chạy cục bộ + 25 đầu ra trong vòng chung
E2 · Đào Đức Tùng (20252612M)	có manifest và corpus đã lưu	có manifest V16, mã PyTorch và wrapper Colab	100 đầu ra cục bộ + 25 đầu ra trong vòng chung
E3 · Nguyễn Công Thanh (20252610M)	có mô tả seed/cách chia	có cấu hình + base/best đã gộp và xuất GGUF	trích đoạn chạy cục bộ + 25 đầu ra trong vòng chung
E4 · Nguyễn Thị Phương Liên (20252130M)	có manifest cho 300/10k	công thức Failure-LoRA có tài liệu; Drive có bốn GGUF	CSV cục bộ + 25 đầu ra trong vòng chung, gồm bản thô/bản repair
E5 · Nguyễn Đình Lê Hoàng (20252737M)	có JSONL huấn luyện/kiểm định	có notebook + checkpoint/adapter/GGUF	25 đầu ra trong vòng chung

Các artifact trên Drive được dùng để đối chiếu dữ liệu, cấu hình và đầu ra của từng hướng. Báo cáo chỉ vẽ biểu đồ từ số đo thực tế đã lưu; không nội suy các đường cong còn thiếu.

Hồ sơ kiến trúc của năm hệ thống đại diện. Cả năm đều là mô hình ngôn ngữ nhân quả kiểu decoder-only: tại mỗi vị trí, mô hình chỉ nhìn các token trước đó rồi dự đoán xác suất của token tiếp theo. Các thiết kế theo phong cách Llama (E1, E3–E5) dùng chuỗi khối `RMSNorm → attention nhân quả có RoPE → residual → RMSNorm → SwiGLU MLP → residual`. Riêng E2 dùng chuỗi khối theo phong cách GPT-2: `LayerNorm → multi-head attention → residual → LayerNorm → GELU MLP → residual`, đồng thời dùng bảng vị trí học được. “GPT 63M” và “Llama 60M” là tên mô tả hai thiết kế do nhóm tự xây dựng, không phải các mô hình GPT hay Llama được phát hành sẵn.

E1 và E2 là **hai lần huấn luyện từ đầu, hoàn toàn độc lập**: E1 tạo `slm-60m`, còn E2 tạo `v16-conditioned`. Hai lần huấn luyện cùng giải một bài toán và cùng được đưa vào vòng đánh giá chung, nhưng không phải hai cấu hình trong cùng một lần chạy, cũng không phải một phép ablation chỉ thay backbone. Vì vậy, sơ đồ dưới đây đặt chúng thành hai luồng riêng; chênh lệch E1–E2 là chênh lệch giữa hai hệ thống, không thể quy riêng cho kiến trúc.



Hình 1: Sơ đồ hai lần huấn luyện độc lập E1 và E2, với hai thiết kế block khác nhau.

Mã huấn luyện PyTorch và cấu hình tham khảo. E2 V16 được huấn luyện thật trên Colab bằng PyTorch và Hugging Face Transformers. Trong `feat/td`, `scripts/train_v16.py` dùng `GPT2Config` và `GPT2LMHeadModel` cho pha tiền huấn luyện, sau đó dùng `AutoModelForCausalLM` và `Trainer`

cho các pha điều kiện hóa và nhân quả; `scripts/colab_v16_train.py` điều phối ba pha trên máy Colab. Sau khi huấn luyện, checkpoint Hugging Face được chuyển thành artifact MLX để chạy cục bộ; MLX không phải framework huấn luyện V16.

Đoạn mã dưới đây dùng `LlamaConfig` và `GPT2Config` để tóm tắt các kích thước cốt lõi của hai thiết kế. E1 và E2 vẫn là hai lần huấn luyện độc lập, với tokenizer và runner riêng. Vì vậy, `docs/model_architecture_configs.py` là bản cấu hình tham khảo dễ đọc, còn implementation huấn luyện thật của E2 nằm ở các script V16 nêu trên.

```
from transformers import GPT2Config, LlamaConfig

llama_cfg = LlamaConfig(
    vocab_size=12_000, hidden_size=768, intermediate_size=2_048,
    num_hidden_layers=8, num_attention_heads=12, num_key_value_heads=4,
    max_position_embeddings=1_024, rope_theta=10_000.0,
    rms_norm_eps=1e-5, tie_word_embeddings=True,
)

gpt2_cfg = GPT2Config(
    vocab_size=16_384, n_positions=1_024, n_ctx=1_024,
    n_embd=768, n_layer=7, n_head=12, n_inner=3_072,
    activation_function="gelu_new", layer_norm_epsilon=1e-5,
    resid_pdrop=0.0, embd_pdrop=0.0, attn_pdrop=0.0,
    tie_word_embeddings=True,
)
```

Khi đọc cấu hình, cần xem các trường này cùng nhau: `num_key_value_heads=4` tạo GQA ở E1, trong khi `n_head=12` ở E2 là multi-head attention đầy đủ; `rope_theta` mô tả RoPE, còn `n_positions/n_ctx` mô tả bảng vị trí học được. Hai lần huấn luyện có cùng hidden size (`hidden_size/n_embd=768`), nhưng khác số block, attention và MLP; đó là khác biệt giữa hai thiết kế và hai lần huấn luyện, không phải một phép so sánh chỉ thay một biến.

Hướng	Số tham số của hệ thống	Số khối × kích thước ẩn	Attention	FFN
E1 · Llama-style 60M	59.560.704	8 × 768	GQA: 12 query head / 4 KV head; 64 chiều/head	SwiGLU, 2.048
E2 · GPT-2-style 63M	62.985.984	7 × 768	MHA: 12 head; 64 chiều/head	GELU-new, 3.072
E3 · SmolLM2-135M + LoRA C	134.515.008 nền + 4.884.480 adapter	30 × 576	GQA: 9 query head / 3 KV head; 64 chiều/head	SwiGLU, 1.536
E4 · Llama 3.2 3B Base + Repair	3.212.749.824; không có adapter trong hệ thống đại diện	28 × 3.072	GQA: 24 query head / 8 KV head; 128 chiều/head	SwiGLU, 8.192
E5 · Llama 3.2 3B + QLoRA	3.212.749.824 sau merge; 24.313.856 tham số LoRA khi train	28 × 3.072	GQA: 24 query head / 8 KV head; 128 chiều/head	SwiGLU, 8.192

Trong cả năm artifact đại diện, embedding đầu vào cũng được dùng làm ma trận chiếu đầu ra. Vì vậy, sau lớp chuẩn hóa cuối, mỗi trạng thái ẩn được chiếu thành một vector logit có kích thước đúng bằng vocabulary; các token có xác suất cao được lấy mẫu để nối tiếp chuỗi.

Hướng	Tokenizer và vocabulary	Cửa sổ ngữ cảnh	Định dạng input → output	Trọng số và artifact dùng để chạy
E1	BPE tương thích GPT-2, 12.000 token; có `<|story|>`, `<|end|>`, `<|pad|>`	huấn luyện: 1.024 token; runner: 2.048	năm trường dạng chỉ dẫn + `<|story|>` → token truyện → `<|end|>`	học toàn bộ 59,56M từ đầu; đánh giá bằng GGUF Q8_0

Hướng	Tokenizer và vocabulary	Cửa sổ ngữ cảnh	Định dạng input → output	Trọng số và artifact dùng để chạy
E2	Metaspace BPE, 16.384 token; sáu thẻ <char>…</char> <moral>…</moral><story>… </story>	1.024 token; pha causal dùng block 512	character + moral trong các thẻ → phần truyện; loss của prompt bị mask	học toàn bộ 62,99M từ đầu bằng PyTorch trên Colab; chuyển sang artifact MLX để phục vụ
E3	GPT-2 BPE của SmolLM2, 49.152 token	mô hình hỗ trợ 8.192; thí nghiệm huấn luyện ở 512	system_message + đề năm trường → phần truyện sinh ra	giữ nguyên base; học LoRA C 4,88M; runner v2 gửi đúng system + prompt
E4	Llama BPE, 128.256 token	mô hình hỗ trợ 131.072; runner dùng 2.048	system + đề năm trường → assistant story → validator → rewrite khi cần → chuẩn hóa Moral:	checkpoint nền Q4_K_M, không huấn luyện thêm trong hệ thống đại diện
E5	Llama BPE, 128.256 token	mô hình hỗ trợ 131.072; huấn luyện và runner dùng 2.048	chat template system/user/assistant với năm trường → assistant story → <|eot_id|>	base 4-bit khi QLoRA; gộp adapter rồi xuất GGUF Q4_K_M

Khi đọc baseline v1, cần lưu ý hai khác biệt về định dạng đầu vào. E1 được huấn luyện với <|story|> nhưng runner v1 truyền trực tiếp đề năm trường; E3 được huấn luyện với system_message + prompt nhưng runner v1 chỉ truyền phần đề. Hai lỗi này đã được sửa trong runner v2: E1 thêm <|story|>, còn E3 gửi đúng system message và prompt huấn luyện. E2, E4 và E5 giữ định dạng artifact đại diện. Các khác biệt này không làm thay đổi kiến trúc mô hình nhưng có thể ảnh hưởng đáng kể đến điểm tuân thủ.

2.2 E1 — Llama 30M/60M huấn luyện từ đầu — Lê Hải Triều (20252611M)

Có bốn nhóm can thiệp được đánh giá trên cùng một dòng mô hình: ngân sách tiền huấn luyện, phân bố dữ liệu, phương pháp hậu huấn luyện và quy mô tham số. Các phép so sánh nội bộ dùng prompt giữ lại để kiểm tra, seed bắt cặp và cùng rubric; điểm nội bộ chỉ dùng để so sánh các biến thể E1.

Dữ liệu và mục tiêu tối ưu. Mỗi mẫu TF1 được mã hóa thành <5 slot + gợi ý độ dài> <|story|> <truyện> <|end|>. Token thuộc prompt bị mask bằng −100; hàm mất mát cross-entropy chỉ được tính trên truyện và token kết thúc. Bộ lọc giữ truyện 60–320 từ. Slot dropout tạo các tập con điều kiện trong quá trình huấn luyện. Tokenizer BPE 12.000 token được huấn luyện riêng để giảm chi phí embedding. Phase 1 dùng 400.000 truyện; Phase 2 giữ cùng quy mô nhưng thay phân bố dữ liệu. Ở lần chạy 60M, sau khi lọc và loại trùng toàn bộ nguồn dữ liệu, còn 2.341.231 truyện, tương đương 934M token, không lặp lại epoch.

Cấu hình mô hình.

Biến thể	Tham số	Khối	Kích thước ẩn / FFN	Query/KV head	Vocabulary	Ngữ cảnh
Llama 30M	36,6M	8	512 / 2.048	8 / 2	12.000	512
slm-60m	59.560.704	8	768 / 2.048	12 / 4	12.000	1.024

Cả hai biến thể dùng RoPE, GQA, RMSNorm, SwiGLU và embedding chia sẻ đầu vào/đầu ra. AdamW có β=(0,9; 0,95), weight decay 0,1 và gradient clip 1,0. Lần chạy 30M dùng fp16 trên T4, batch hiệu dụng 128 chuỗi, khoảng 33k token/bước. Lịch Warmup–Stable–Decay (WSD) có warmup 2%, giữ LR đỉnh 3e−3, rồi decay trong 20% số bước cuối mỗi pha. Lần chạy 60M dùng cùng công thức tối ưu hóa và lưu checkpoint mỗi 500 bước.

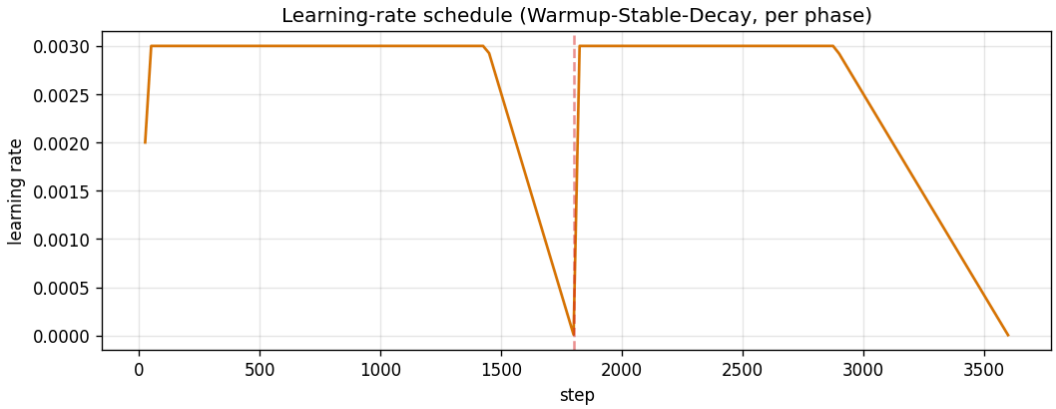
Quá trình tiền huấn luyện. Mốc v1 cố ý dùng ngân sách thấp để kiểm tra giả thuyết mô hình chưa được huấn luyện đủ. Phase 1 tăng số token nhưng giữ nguyên kiến trúc; Phase 2 tiếp tục từ cùng

checkpoint và thay phân bố corpus; lần chạy 60M đồng thời thay đổi quy mô mô hình, độ dài ngữ cảnh và số token.

Giai đoạn	Dữ liệu / bước	Loss cuối	PPL trên tập giữ lại	Điểm giám khảo nội bộ	Can thiệp
v1 30M	150k / 900	~1,80	—	2,50	khoảng 1,7 token/tham số
Phase 1 30M	400k / 1.800	1,447	4,18	6,00	khoảng 600M token qua bốn epoch
Phase 1 + sửa sampling	như trên	—	—	6,20	repetition penalty 1,3 → 1,1
Phase 2 30M	400k-v2 / 3.600	1,278	3,56	7,00	can thiệp phân bố dữ liệu
60M	2,34M / 10.000	1,058	2,87	8,96	toàn bộ TF1, ngữ cảnh 1.024



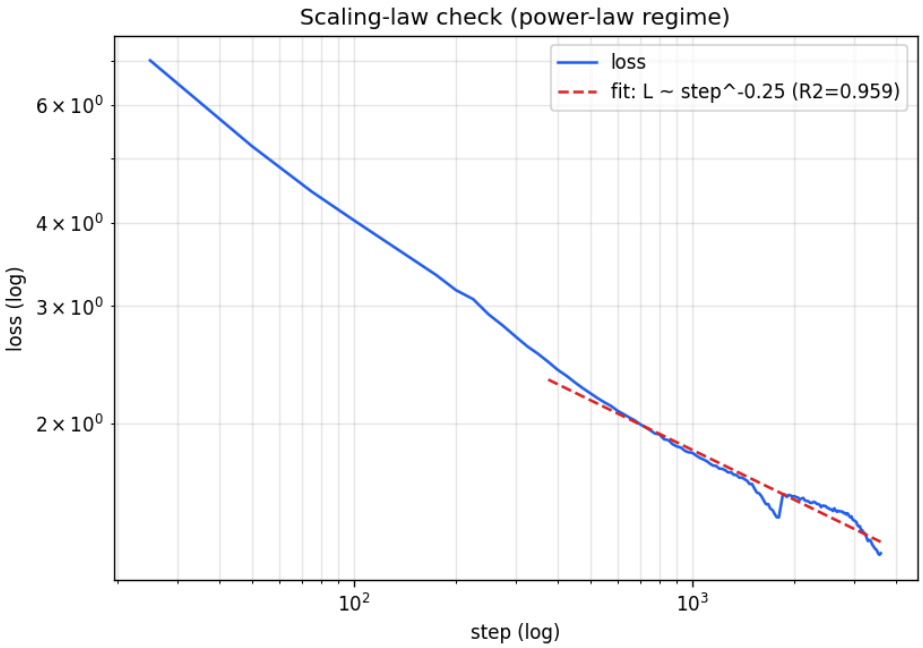
Hình 2: Loss 30M theo bước; Phase 2 resume tại bước 1.800.



Hình 3: Lịch tốc độ học WSD của run 30M.

Loss giảm đều và không xuất hiện spike đáng kể. Mỗi giai đoạn decay tạo thêm một mức giảm ở cuối pha, phù hợp với lịch WSD. Các giá trị 1,447 và 1,278 là loss của cửa sổ log cuối, không phải trường `train_loss` tổng hợp của Hugging Face.

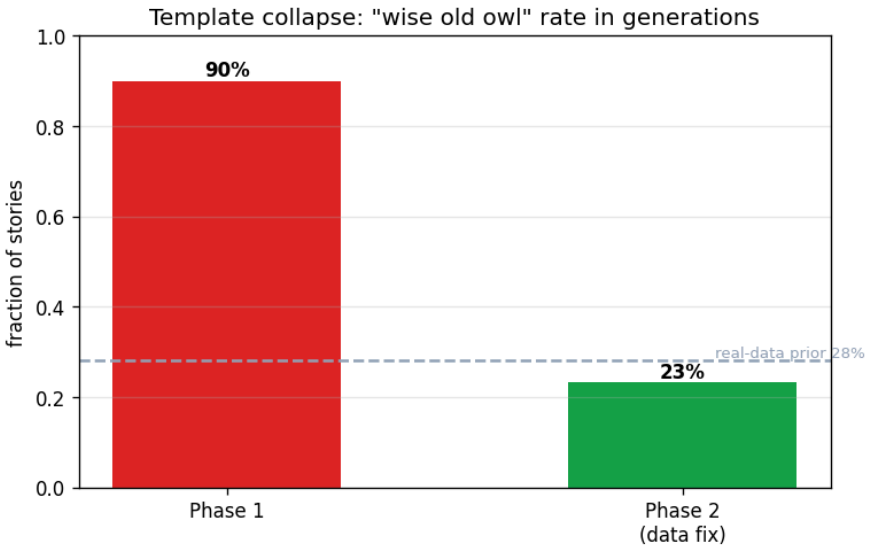
Chẩn đoán theo scaling law. Mốc v1 chỉ dùng khoảng 1,7 token/tham số và đạt 2,50/10. Khi giữ nguyên mô hình nhưng tăng ngân sách lên khoảng 600M token, điểm judge tăng lên 6,00 và loss giảm mạnh. Phép fit log-log trên loss sau warmup cho R^2=0,96; đường cong chưa có dấu hiệu bão hòa trong phạm vi quan sát. Kết quả này ủng hộ giả thuyết mô hình chưa được huấn luyện đủ ở cấu hình v1 và tạo cơ sở thực nghiệm để tăng ngân sách trước khi thay kiến trúc.



Hình 4: Kiểm tra chế độ power-law của loss theo số bước.

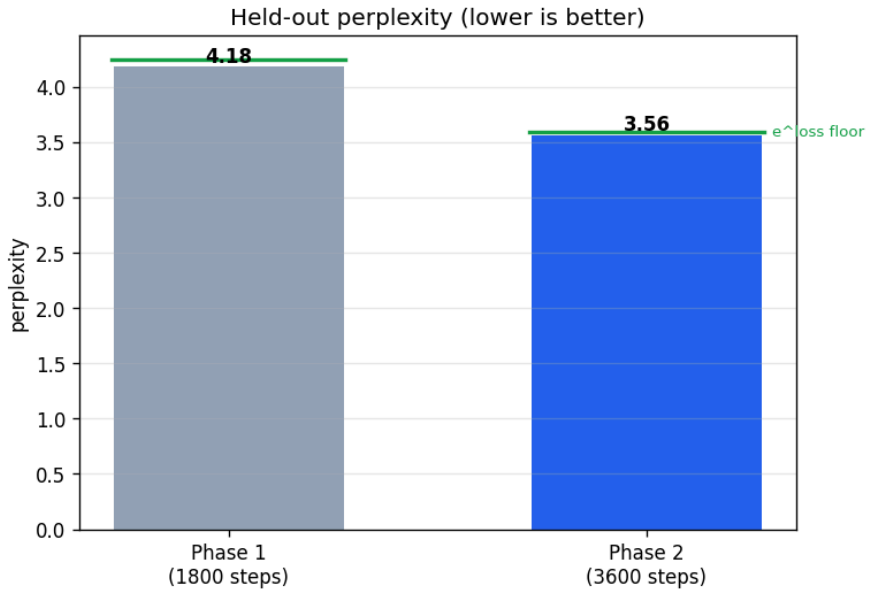
Một thay đổi ở bước giải mã cũng được kiểm tra riêng. Repetition penalty 1,3 phạt cả việc lặp tên nhân vật, làm danh tính nhân vật thay đổi giữa truyện; giảm xuống 1,1 tăng điểm nội bộ 6,00 → 6,20 mà không cập nhật trọng số. Kết quả này được xem là hiệu ứng của decoding, không gộp vào hiệu ứng tiền huấn luyện.

Can thiệp phân bố dữ liệu. Phân tích đầu ra Phase 1 cho thấy cụm `wise old owl` xuất hiện trong khoảng 90% truyện sinh, trong khi tỷ lệ trong dữ liệu gốc chỉ là 28%. Phase 2 giới hạn mẫu chứa cụm này ở 10% và giảm slot dropout của `Teaching` và `Outcome` từ 0,30 xuống 0,15. Sau can thiệp, tỷ lệ cụm trong đầu ra giảm còn 23%. Điều này cho thấy hiện tượng mode collapse cục bộ có thể được xử lý ở phân bố huấn luyện thay vì tăng thêm ràng buộc khi lấy mẫu.

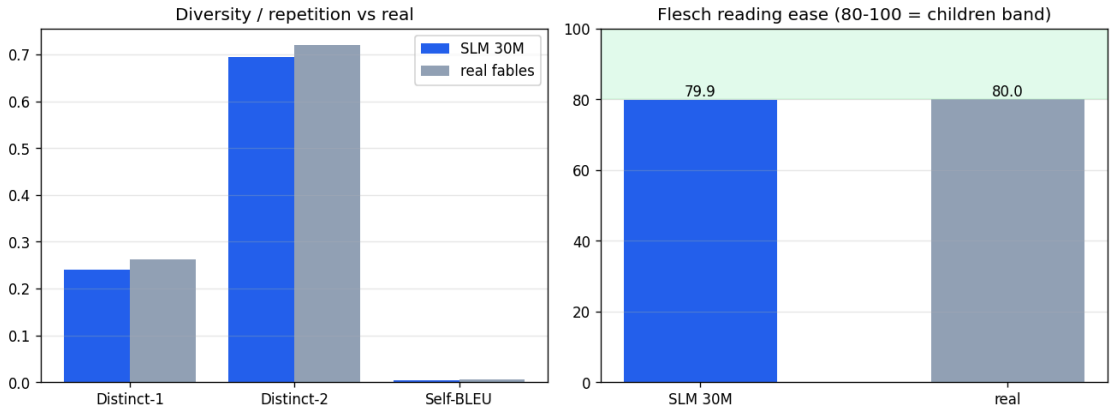


Hình 5: Tỷ lệ khuôn mẫu “wise old owl” trước và sau can thiệp dữ liệu.

PPL trên tập giữ lại giảm từ 4,18 xuống 3,56. Mốc 3,56 gần với $\exp(1{,}278) = 3{,}59$, cho thấy khoảng cách giữa loss cuối và PPL trên tập giữ lại nhỏ trong cách đo của E1. Các chỉ số cũng được so với truyện thật: Distinct-2 lệch khoảng 4%, Self-BLEU lệch 0,001 và Flesch 79,9 so với 80,0. Những số đo này xác nhận hình dạng thống kê và độ dễ đọc, nhưng không được dùng thay cho kiểm tra tuân thủ điều kiện.

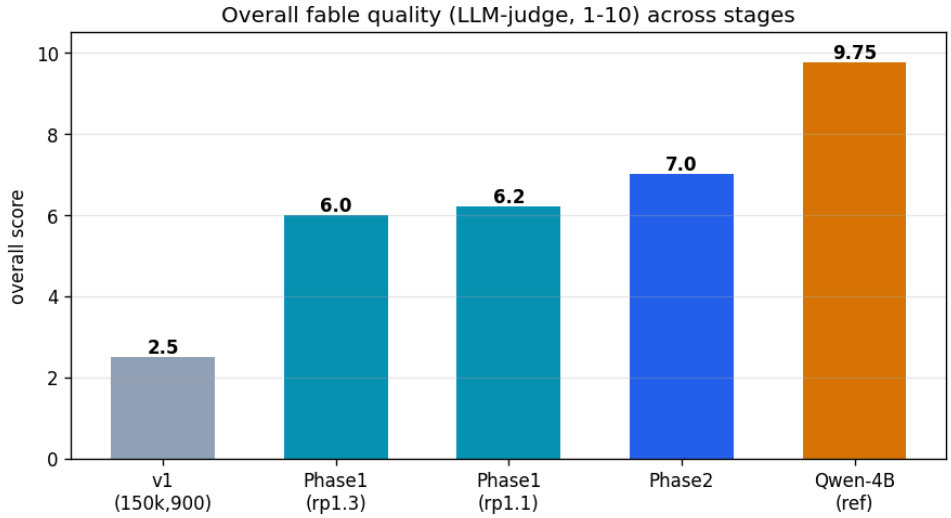


Hình 6: Perplexity held-out của Phase 1 và Phase 2.



Hình 7: Đa dạng, mức lặp và độ dễ đọc của truyện sinh so với truyện thật.

Điểm giám khảo nội bộ tăng theo ba kiểu can thiệp: ngân sách token tạo mức tăng lớn nhất ở 30M; sửa decoding tạo mức tăng nhỏ; thay phân bố dữ liệu tiếp tục cải thiện mức độ bám điều kiện và giảm khuôn mẫu.



Hình 8: Điểm judge nội bộ qua các mốc E1.

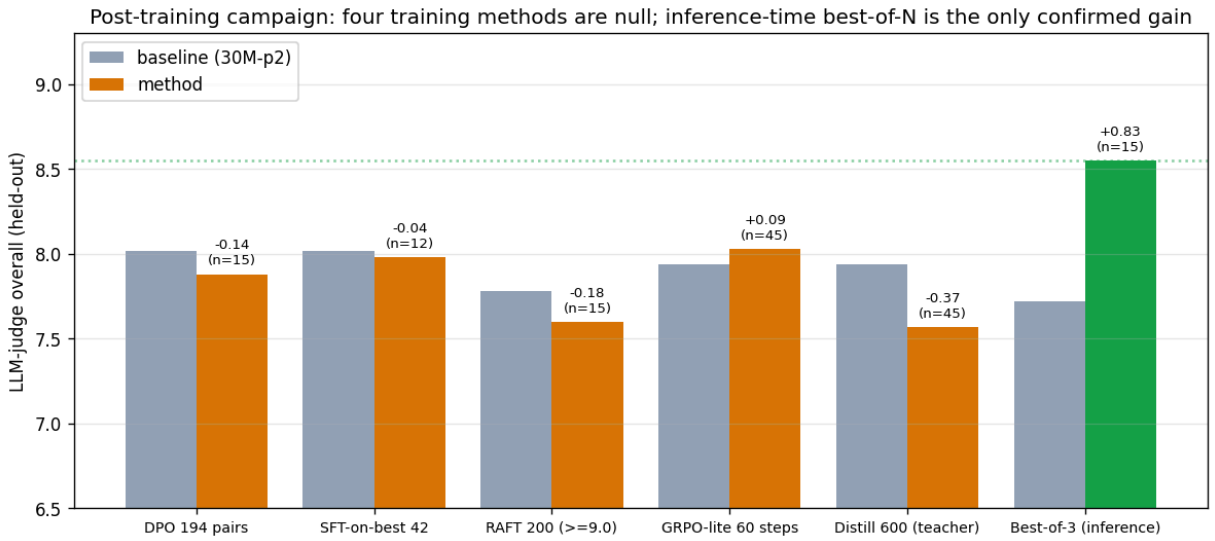
Phân tích hậu huấn luyện và suy luận. Sau Phase 2, các phương pháp được đánh giá bằng cùng prompt giữ lại để kiểm tra và cùng baseline trong một phiên:

Phương pháp	Cơ chế	Tín hiệu học trong E1	Có cập nhật trọng số?
DPO — Direct Preference Optimization	tăng xác suất tương đối của truyện được chọn so với truyện bị loại, đồng thời neo vào mô hình tham chiếu	194 cặp `chosen/rejected` có chênh điểm judge ≥1	có
SFT-on-best — tinh chỉnh có giám sát trên mẫu tốt nhất	chọn truyện tốt nhất trong mỗi nhóm ứng viên rồi tối ưu cross-entropy với truyện đó làm đích	42 truyện thắng tương đối trong nhóm	có
RAFT — Reward-Ranked Fine-Tuning	sinh, chấm điểm, lọc theo ngưỡng tuyệt đối rồi SFT lại trên tập được nhận	200 truyện tự sinh có điểm judge ≥9,0	có
GRPO-lite — tối ưu chính sách tương đối theo nhóm	sinh rollout mới, chuẩn hóa reward trong nhóm cùng prompt, cập nhật REINFORCE và phạt KL so với mô hình gốc	60 bước × 16 rollout; reward từ judge	có

Phương pháp	Cơ chế	Tín hiệu học trong E1	Có cập nhật trọng số?
Distillation — chưng cất đầu ra	dùng truyện của mô hình teacher làm đích SFT; E1 không dùng soft logits	600 truyện do Qwen3-4B sinh	có
Best-of-N — chọn mẫu ở bước suy luận	sinh N ứng viên và trả về ứng viên có điểm judge cao nhất	N=3; temperature 0,5/0,8/1,1	không

SFT-on-best dùng thứ hạng **tương đối** trong một nhóm nhỏ, còn RAFT dùng ngưỡng **tuyệt đối** trên toàn tập sinh. `GRPO-lite` là biến thể REINFORCE có baseline theo nhóm của E1, không phải một triển khai đầy đủ mọi thành phần của GRPO. Tất cả điểm và kết luận từ đây đến hết tiểu mục là **đánh giá nội bộ E1**; chúng không thuộc vòng chấm Gemma thống nhất ở Mục 4.

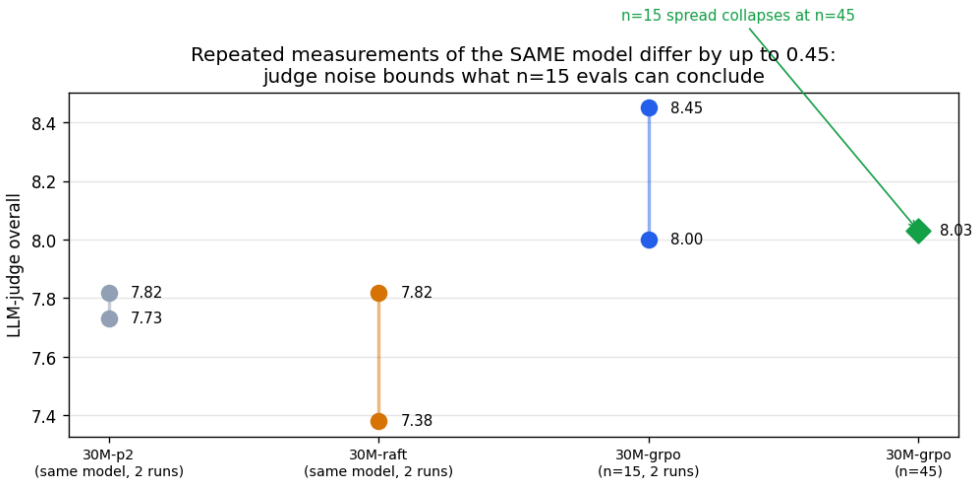
Can thiệp	Baseline	Kết quả	Diễn giải trong E1
DPO, 194 cặp	8,02	7,88	không cải thiện
SFT trên mẫu tốt nhất	8,02	7,98	không cải thiện
RAFT, 200 mẫu ≥9,0	7,78	7,60	không cải thiện
GRPO-lite, n=45	—	+0,09; t=0,54	hiệu ứng nằm trong nhiễu
Distillation, 600 mẫu	7,94	7,57	giảm 0,37; PPL drift +4,4%
Best-of-3	7,72	**8,55**	tăng khoảng 0,8 tại suy luận



Hình 9: Kết quả chiến dịch hậu huấn luyện và Best-of-N dưới cùng protocol E1.

DPO học phân biệt chosen/rejected trên tập huấn luyện nhưng không làm thay đổi phân bố trên tập giữ lại. RAFT và SFT chỉ tăng trọng số cho những mẫu vốn đã nằm trong phân bố dữ liệu, không có gradient âm để loại bỏ các mode yếu. GRPO có bước khám phá và gradient âm, nhưng KL cuối chỉ khoảng `1e-3` nat/token nên chính sách gần như không đổi trong ngân sách 60 bước. Distillation là can thiệp duy nhất tạo ra độ lệch rõ, nhưng mô hình nhỏ học theo văn phong của teacher và làm giảm chất lượng. Ngược lại, Best-of-N không thay đổi phân bố; nó khai thác những mẫu tốt đã tồn tại và làm giảm phương sai lựa chọn.

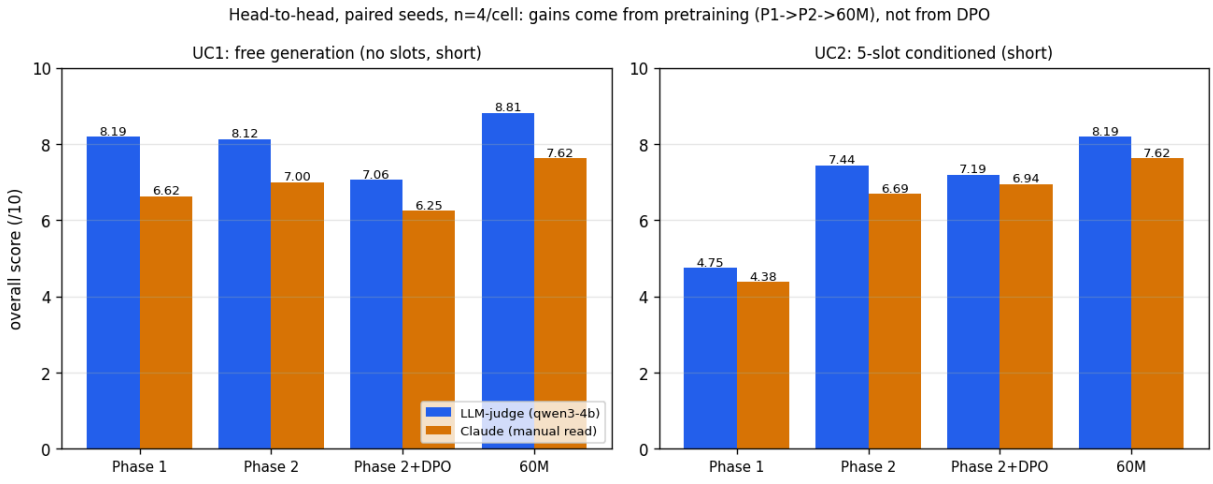
Độ tin cậy của giám khảo nội bộ. Khi chấm lại cùng một checkpoint, điểm dao động khoảng ±0,4 điểm ở n=15. Vì vậy, E1 quy ước rằng chênh lệch dưới 0,5 tại n=15 chưa đủ để kết luận và xác nhận các kết quả chính ở n=45 với seed bắt cặp. Quy tắc này khiến hai kết quả sơ bộ không còn được giữ: DPO tăng adherence và GRPO tăng 0,45 điểm.



Hình 10: Độ biến thiên khi chấm lặp cùng checkpoint và ảnh hưởng của cỡ mẫu.

Kiểm tra trên ứng dụng. Phase 1, Phase 2 và Phase 2+DPO được chạy ở hai chế độ: sinh tự do và sinh với đủ năm trường. Mỗi ô gồm bốn prompt, seed bắt cặp; đầu ra được giám khảo Qwen3-4B của ứng dụng chấm và được Claude đọc độc lập thêm một lượt. Hai giám khảo cho cùng thứ tự tương đối. DPO thường tạo chuỗi giống Phase 2 trên phần lớn độ dài và chỉ rẽ nhánh ở đoạn cuối, phù hợp với kết luận rằng cập nhật này không dịch phân bố đáng kể.

Biến thể	Sinh tự do: giám khảo / Claude	Đủ năm trường: giám khảo / Claude	Độ tuân thủ đủ năm trường
Phase 1	8,19 / 6,62	4,75 / 4,38	3,5
Phase 2	8,12 / 7,00	7,44 / 6,69	7,0
Phase 2+DPO	7,06 / 6,25	7,19 / 6,94	5,8
60M	**8,81 / 7,62**	**8,19 / 7,62**	**8,0**



Hình 11: Đối đầu các checkpoint E1 trong hai chế độ sinh và với hai giám khảo.

Kiểm chứng bằng tăng quy mô tiền huấn luyện. `slm-60m` có chính xác 59.560.704 tham số, ngữ cảnh 1.024 và được huấn luyện 10.000 bước trên 934M token. Loss cuối là 1,058, PPL trên tập giữ lại là 2,87. Trên 45 prompt seed bắt cặp của quy trình E1, mô hình 60M tăng 1,017 điểm so với 30M Phase 2, với t=6,53; cao hơn ở 36 đề, bằng ở 5 đề và thấp hơn ở 4 đề.

Chỉ số nội bộ E1, n=45	30M Phase 2	60M	Chênh lệch
Điểm tổng thể	7,939	**8,956**	**+1,017**
Prompt adherence	7,87	**9,11**	+1,24
Thắng / hòa / thua	—	—	36 / 5 / 4

Đây là phép so sánh dương rõ nhất trong E1, nhưng không phải một thí nghiệm loại trừ chỉ thay một biến: 60M đồng thời tăng số tham số, context và ngân sách dữ liệu. Kết quả chỉ xác nhận rằng gói scale-up tiền huấn luyện hiệu quả hơn các cấu hình hậu huấn luyện đã thử; nó không định lượng riêng đóng góp của từng thành phần.

Quan hệ với đánh giá thống nhất. Điểm 8,956 ở trên thuộc judge và prompt contract nội bộ của E1. Baseline vòng chung v1 dùng runner chưa thêm token `<|story|>` và Gemma chấm theo rubric khác, nên `slm-60m` đạt 3,30/10. Sau khi sửa runner, lượt v2 đủ 25 đề đạt **4,60/10** (grammar 8,48; creativity 4,24; moral clarity 4,04; prompt adherence 1,64; CI [4,38; 4,83]). Đây là tín hiệu đo trên giao diện đã khớp hơn, nhưng không thể quy toàn bộ chênh lệch 3,30 → 4,60 riêng cho token phân cách vì v2 đồng thời sinh lại đầu ra và dùng rubric judge không chấm literal `Moral:`.

Kết luận E1. Kết quả nội bộ cho thấy chất lượng mặc định của mô hình nhỏ phụ thuộc chủ yếu vào nền tiền huấn luyện. Khi mô hình 30M được cấp đủ ngân sách token, loss, perplexity, độ trôi chảy và khả năng bám năm trường đều cải thiện so với pha chẩn đoán ban đầu. Trong nhóm hậu huấn luyện, DPO, SFT trên mẫu tốt, RAFT và GRPO-lite không tạo chênh lệch vượt mức nhiễu đo được của giám khảo; distillation từ teacher còn làm giảm chất lượng. Trái lại, gói tăng quy mô lên 60M, ngữ cảnh 1.024 và 934M token tiền huấn luyện tăng điểm bắt cặp 1,017 trên 45 đề và cao hơn ở 36/45 đề. Bằng chứng này ủng hộ việc đầu tư vào phân bố tiền huấn luyện hơn là tiếp tục tối ưu cục bộ trên vài trăm mẫu hậu huấn luyện.

Best-of-N làm rõ một khía cạnh khác của phân bố sinh. Một lần lấy mẫu từ mô hình 30M đạt trung bình 7,72, trong khi chọn tốt nhất trong ba ứng viên đạt 8,55. Mô hình vì vậy đã gán xác suất khác không cho các truyện tốt, nhưng chưa tập trung đủ xác suất vào chúng để một lần sinh mặc định đạt chất lượng ổn định. Các phương pháp hậu huấn luyện đã thử không đưa được lợi ích này vào mô hình: dữ liệu preference tự sinh có biên chất lượng hẹp, tập mẫu tốt quá nhỏ so với phân bố tiền huấn luyện ban đầu, còn dữ liệu từ teacher lệch phân bố so với năng lực học trò. Kết quả không phủ định DPO, RAFT hay distillation nói chung; nó giới hạn kết luận ở kích thước dữ liệu, tín hiệu judge và cấu hình tối ưu của E1.

So sánh 30M với 60M cũng không phải một thí nghiệm loại trừ riêng cho số tham số, vì số tham số, cửa sổ ngữ cảnh và ngân sách token thay đổi đồng thời. Do đó không thể suy ra một ngưỡng năng lực phổ quát từ phép đo này. Kết luận hợp lệ là toàn bộ gói tăng quy mô cải thiện rõ phân bố sinh mặc định, trong khi các can thiệp hậu huấn luyện chi phí thấp đã thử không tạo mức cải thiện tương đương. Việc tự đo nhiễu của giám khảo khoảng ±0,4 điểm còn cho thấy các chênh lệch nhỏ phải được chấm lặp hoặc đánh giá trên mẫu lớn hơn trước khi xem là hiệu ứng thực sự.

Điểm 3,30 của baseline v1 không phủ định các thí nghiệm loại trừ nội bộ, nhưng bộc lộ một lỗi triển khai: checkpoint được huấn luyện với token `<|story|>` trong khi runner v1 không truyền token đó. Runner v2 đã khớp lại hợp đồng này; điểm v2 **4,60/10** là kết quả tương ứng cần dùng khi trình bày E1 sau bản sửa. `slm-60m` được chọn làm đại diện E1 vì là checkpoint trực tiếp tốt nhất của hướng này; best-of-N được xem là lớp tìm kiếm lúc suy luận, không được trộn vào chất lượng một lần sinh của checkpoint. Mẫu định tính và trường hợp thay thế điều kiện được trình bày ở Mục 2.7.

2.3 E2 — GPT 63M huấn luyện từ đầu — Đào Đức Tùng (20252612M)

E2 tập trung vào ba vấn đề: chất lượng biểu diễn token, khả năng dùng hai trường `character + moral` làm điều kiện đầu vào, và khả năng biến điều kiện đó thành chuỗi tính cách→lựa chọn→hệ quả. Toàn bộ checkpoint được huấn luyện từ khởi tạo ngẫu nhiên hoặc tiếp tục từ checkpoint do chính E2 tạo ra; không sử dụng mô hình ngôn ngữ đã tiền huấn luyện làm trọng số khởi đầu. Các điểm trong tiểu mục này thuộc quy trình đánh giá nội bộ E2 và chỉ dùng để so sánh các biến thể E2.

Thiết kế thực nghiệm. Các biến thể được tổ chức thành những thí nghiệm nối tiếp theo từng giả thuyết; mỗi kết luận chỉ dựa trên so sánh có đối chứng trong cùng hàng:

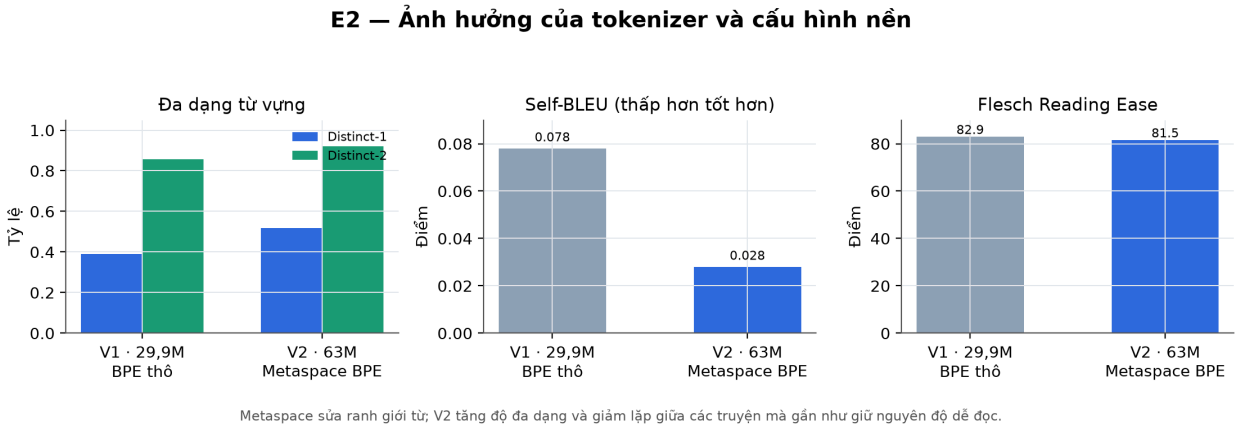
Nhóm biến thể	Nội dung thay đổi	Đối chứng	Kết quả đo được
V1–V3	tokenizer, quy mô 29,9M→63M và prompt masking	V1/V2; V2/V3	sửa lỗi ranh giới từ; bám đúng trường đầu vào hơn và kết thúc sạch
V4–V6	thêm dữ liệu TF1, 189 truyện người viết, 280 truyện nhân quả	checkpoint V3	lượng dữ liệu bổ sung quá nhỏ hoặc không cải thiện
V7–V8	sinh `plan + story` so với chưng cất trực tiếp story	cùng teacher corpus	bỏ dàn ý làm giảm độ lệch khi chạy thật nhưng chưa tạo được causal-pass
V9–V10	trộn replay với 6.278 rồi 13.270 truyện nhân quả	V8 và V3	giữ được độ trôi chảy; causal pass không tăng
V11	thêm thẻ ngữ nghĩa `<moral_class>`	cùng trọng số, có/bỏ thẻ	thẻ lớp kích hoạt kiểu truyện ngắn, không tạo được khả năng lập kế hoạch
V12	tăng riêng số layer: 63M→98M	cùng tokenizer, dữ liệu, seed và lịch train	causal pass +1 điểm %, CI chạm 0
V13	DPO trên cặp teacher/failure đã khớp độ dài	V12-98M	độ chính xác chọn truyện tốt hơn đạt 54,4%; causal-pass không đổi
V14	tám epoch chỉ dùng dữ liệu nhân quả	V3	fluency giảm; causal pass 0–5%
V15	loss phụ liên kết story–moral	V3	matching đạt 75,4%; không chuyển thành khả năng sinh tự do
V16	tăng tiền huấn luyện 200k→500k rồi điều kiện hóa/nhân quả	V3 và ba epoch causal	fluency tăng trước khi học nhân quả; liên kết nhân quả không tăng

Chuẩn bị dữ liệu. TF1-EN-3M được đọc tuần tự; các bản ghi tiếng Anh có `character`, `moral` hợp lệ và thân truyện dài tối thiểu 80 ký tự mới được giữ lại. Corpus V16 gồm 500.000 bản ghi hợp lệ đầu tiên theo thứ tự nguồn. Pha điều kiện hóa lọc tiếp những truyện có cụm nhân vật xuất hiện nguyên văn, thu được 108.487 mẫu: 103.063 mẫu train và 5.424 validation với seed 42. Prefix chứa `character + moral`; target là thân truyện và `</story>`. Nhãn của toàn bộ token prefix được đặt `−100`, nên gradient chỉ đến từ phần truyện.

Corpus nhân quả được xây riêng để kiểm tra lỗi thiếu liên kết ngữ nghĩa. Teacher 31B sinh truyện theo chuỗi conflict→choice→consequence; một mô hình chấm điểm 26B chỉ giữ lại các mẫu đạt yêu cầu về nhân vật, liên kết sự kiện, bài học và kết thúc. Trong 11.458 mẫu mới được chấm, 7.665 mẫu đạt strict-pass. Sau khi gộp 6.278 mẫu strict từ V8 và loại trùng, tập train nhân quả có 13.270 mẫu, phủ 100 bài học. Hai tập đánh giá cố định gồm các moral chưa xuất hiện và các cặp `character–moral` được giữ lại để kiểm tra; vòng sàng lọc dùng 20 đề, còn đánh giá đầy đủ dùng 100 đề khi cấu hình đạt điều kiện.

Tokenizer. V1 dùng BPE 8.192 token mà không có bước tiền tách token. Khoảng trắng được học như ký tự thông thường, dẫn đến các từ bị tách vụn như `par ty` và `w o ven`. Từ V2, tokenizer được cố định ở Metaspace BPE 16.384 token: khoảng trắng được mã hóa bằng sentinel trước BPE và phục hồi khi decode. Phép kiểm tra round-trip trên văn bản giữ lại không làm thay đổi chuỗi.

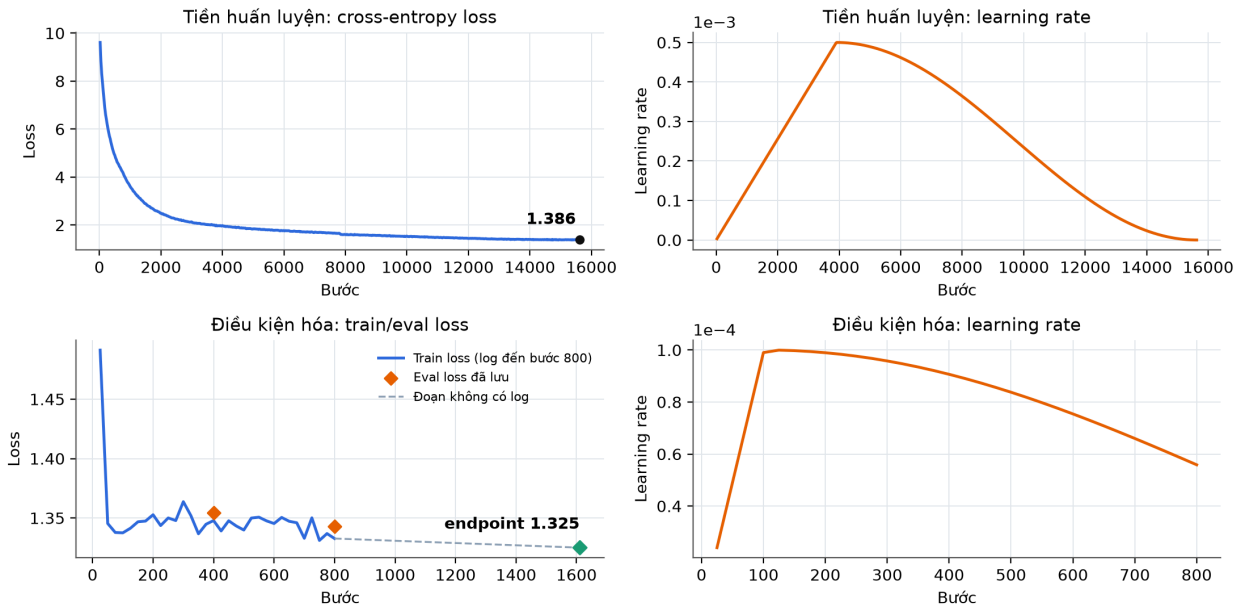
V1 và V2 đồng thời khác quy mô mô hình, vocabulary và số bước huấn luyện; vì vậy biểu đồ dưới đo hiệu quả của **toàn bộ gói thay đổi cấu hình**, không cô lập riêng tokenizer. Distinct-1 và Distinct-2 tăng, Self-BLEU giảm, còn Flesch gần như giữ nguyên. Kết hợp với việc lỗi vỡ từ biến mất, kết quả xác nhận chất lượng bề mặt được cải thiện mà không làm văn bản khó đọc hơn.



Hình 12: E2: so sánh chỉ số không cần tham chiếu giữa V1 dùng BPE thô và V2 dùng Metaspace BPE. Hai cấu hình còn khác quy mô mô hình và vocabulary, nên đây không phải thí nghiệm loại trừ chỉ thay tokenizer.

Kiến trúc và ba pha huấn luyện. "GPT 63M" là một `GPT2LMHeadModel` được khởi tạo từ đầu với đúng 62.985.984 tham số, không phải một checkpoint GPT có sẵn. Mô hình gồm embedding token `16.384 × 768`, embedding vị trí học được cho 1.024 vị trí, bảy khối decoder và một LayerNorm cuối. Mỗi khối gồm causal self-attention 12 head (64 chiều/head) và MLP GELU-new `768 → 3.072 → 768`; output head dùng chung trọng số với token embedding. Đầu vào có điều kiện có dạng `<char>…</char><moral>…</moral><story>`; mô hình sinh token truyện cho tới `</story>`, và loss chỉ tính trên phần truyện. Ba pha V16 được chạy bằng PyTorch và Hugging Face Transformers trên Colab, dùng một GPU A100 trong thời lượng 100 phút:

Pha	Dữ liệu	Epoch/bước	LR	Weight decay	Loss cuối
Tiền huấn luyện	500.000	2 / 15.625	5e−4	0,1	1,386
Điều kiện hóa	103.063	— / 1.611	1e−4	—	1,325
Chỉ-nhân-quả	13.270	3 / 624	3e−6	—	train 2,451; val nhân quả 2,394; val replay 1,597



Nguồn: artifact huấn luyện V16. Log theo bước của pha điều kiện hóa kết thúc ở bước 800; điểm cuối tại bước 1.611 được đánh dấu riêng.

Hình 13: E2: đường loss và lịch tốc độ học trong hai pha tiền huấn luyện và điều kiện hóa. Nét đứt biểu thị đoạn không có log theo bước; điểm cuối là số đo thực tế, không phải kết quả nội suy.

Biểu đồ cho thấy loss của pha tiền huấn luyện giảm nhanh ở giai đoạn đầu rồi dần ổn định. Sang pha điều kiện hóa, loss huấn luyện và loss đánh giá tiếp tục giảm, còn tốc độ học thay đổi đúng theo lịch warmup–decay đã thiết kế. Không quan sát thấy dao động bất thường hoặc dấu hiệu phân kỳ. Kết quả này xác nhận quá trình tối ưu diễn ra ổn định, nhưng chưa đủ để kết luận mô hình đã học được quan hệ nhân quả: loss phản ánh mức độ phù hợp với phân bố token huấn luyện, chứ không trực tiếp đo việc các điều kiện đầu vào có thực sự chi phối diễn biến truyện hay không.

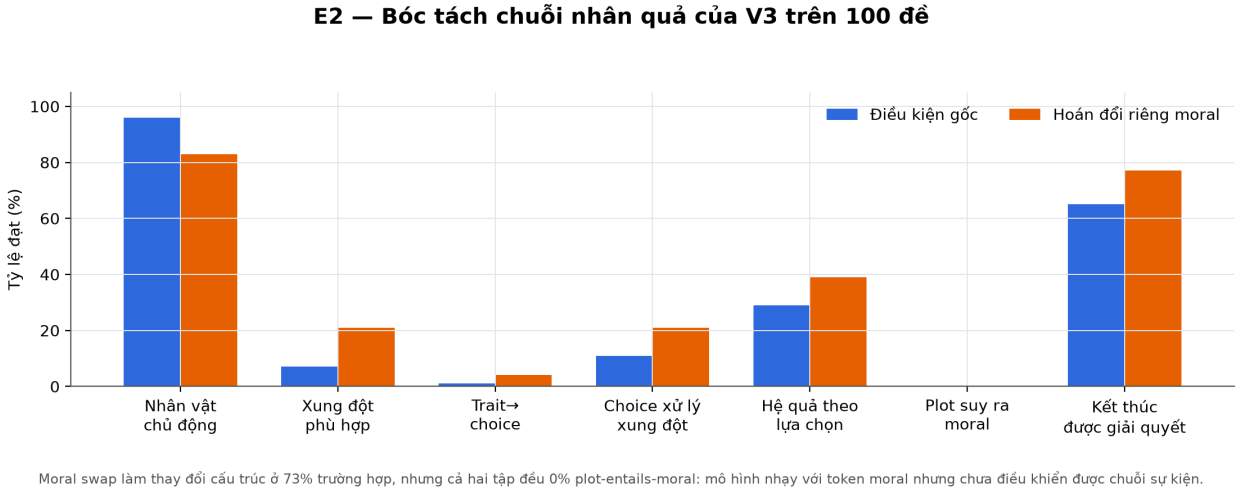
Hiệu quả của gói thay đổi V1→V2. Sửa tokenizer, tăng vocabulary và tăng mô hình từ 29,9M lên 63M cải thiện đồng thời các chỉ số nội tại:

Chỉ số nội bộ	29.9M	63M	Thay đổi
Distinct-1	0.389	0.519	+33%
Distinct-2	0.857	0.922	+8%
Self-BLEU	0.078	0.028	giảm 64%
Flesch	82.9	81.5	gần như giữ nguyên

V3 — điều kiện hóa có mask. So với V2, V3 giữ nguyên 63M tham số và tokenizer, nhưng chuyển 103.063 mẫu sang mục tiêu chỉ tính loss trên phần truyện. Trên 100 đề, khớp chính xác character tăng từ 18% lên 65%, khớp chính xác moral từ 17% lên 86%, khớp cả hai từ 3% lên 55%, và tỷ lệ sinh `</story>` tăng từ 0% lên 100%. Điểm chấm nội bộ ban đầu tăng từ 5,06 lên 6,78. Các chỉ số này cho thấy prompt masking giúp mô hình sao chép đúng hai trường và dừng sạch hơn; chúng chưa cho biết diễn biến có chứng minh bài học hay không.

Sau đó, 100 thân truyện được chấm lại bằng bộ tiêu chí gồm bảy liên kết. V3 đạt fluency 6,21/10 và dùng đúng nhân vật làm tác nhân ở 96% mẫu, nhưng chỉ 7% có xung đột liên quan đến bài học, 1% có tính cách chi phối lựa chọn và 0% có diễn biến suy ra được bài học. Khi chỉ hoán đổi

moral, cấu trúc conflict/choice/consequence thay đổi trong 73% cặp nhưng tỷ lệ plot-entails-moral vẫn bằng 0%. Mô hình vì vậy **nhạy với chuỗi token điều kiện** nhưng chưa dùng điều kiện theo quan hệ được yêu cầu.



Hình 14: E2: tỷ lệ vượt từng liên kết của chuỗi nhân quả trên 100 đề gốc và 100 biến thể chỉ hoán đổi moral.

Kết quả này dẫn đến ba tầng đánh giá độc lập cho E2:

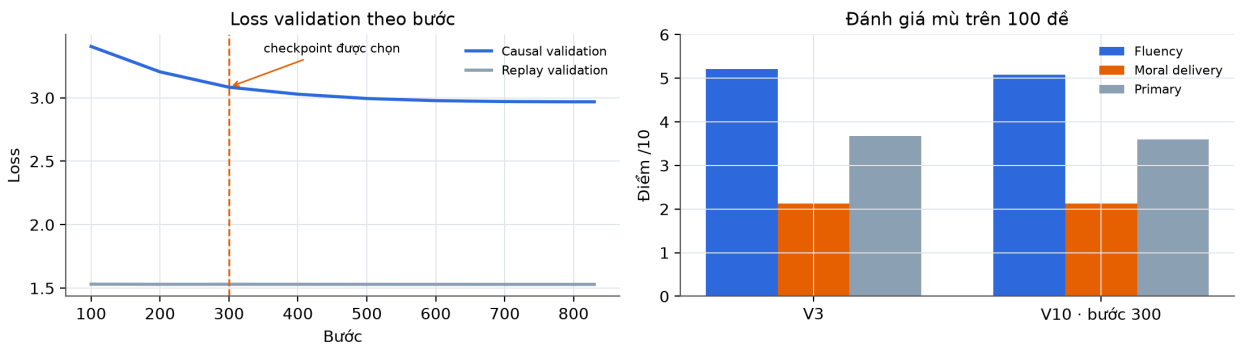
1. **Bám đúng đầu vào:** nhân vật và bài học có xuất hiện, truyện có kết thúc sạch;
2. **Liên kết nhân quả:** tính cách chi phối lựa chọn, lựa chọn xử lý xung đột và hệ quả phát sinh từ lựa chọn;
3. **Bài học được suy ra:** bài học phải xuất phát từ chuỗi sự kiện, không chỉ được chép ở cuối truyện.

Dữ liệu teacher và replay — V7 đến V10. V7 yêu cầu mô hình sinh cả dàn ý rồi mới viết truyện. Khi chạy thật, truyện lại phụ thuộc vào dàn ý do chính mô hình nhỏ tạo, nên lỗi ở dàn ý truyền trực tiếp sang phần truyện. V8 bỏ dàn ý khỏi đầu ra và chưng cất trực tiếp thân truyện do teacher sinh. Các truyện đích của teacher đạt fluency 7,75 và moral-delivery 8,28, nhưng checkpoint V8 tốt nhất chỉ đạt 4,65 và khoảng 1,70 khi sinh tự do; loss thấp khi ép mô hình bám theo truyện đích không chuyển thành quá trình sinh ổn định.

V9 và V10 kiểm tra liệu replay từ V3 có giữ chất lượng bề mặt khi học thêm dữ liệu nhân quả hay không:

Biến thể	Hỗn hợp huấn luyện	Đánh giá nội bộ	Kết luận trong E2
V9	6.278 causal (25%) + 18.834 replay (75%)	fluency 5,67; moral 2,02; causal-pass 0%	replay phục hồi độ trôi chảy, không tạo liên kết nhân quả
V10	13.270 causal (25%) + 39.810 replay (75%)	V10/V3 primary 3,60/3,67; causal-pass cùng 2%	tăng gấp đôi dữ liệu nhân quả không làm causal-pass thay đổi

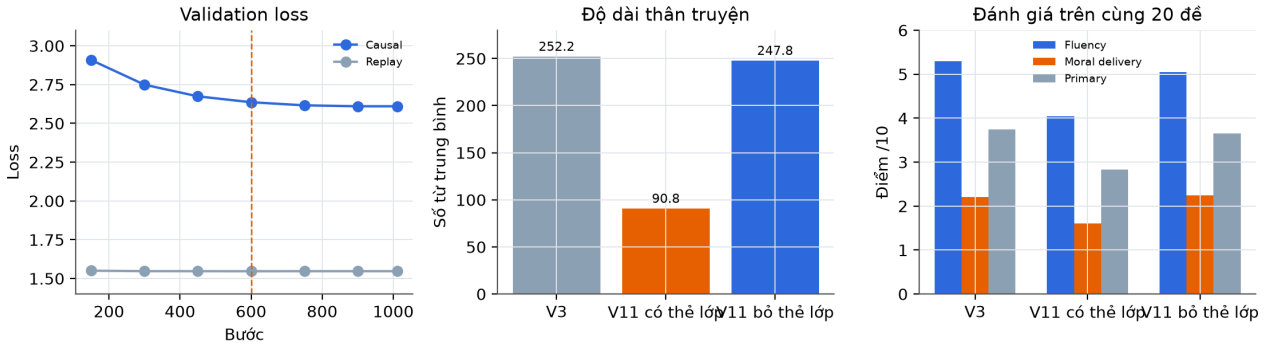
V10 huấn luyện 830 bước, LR 3e−6, cosine decay và batch hiệu dụng 64. Loss đánh giá nhân quả giảm 3,404→2,968; replay loss giữ gần 1,530. Checkpoint bước 300 được chọn qua vòng sàng lọc, sau đó so sánh mù với V3 trên 100 đề: V3 thắng 40, V10 thắng 36 và hòa 24. Chênh primary V10−V3 là −0,06 với CI bootstrap 95% [−0,25; 0,125]. Loss trên target nhân quả giảm rõ nhưng causal-pass không đổi; đây là bằng chứng trực tiếp rằng validation loss không đủ làm tiêu chí chọn checkpoint cho sinh có điều kiện.



Hình 15: E2: V10 giảm causal validation loss nhưng không cải thiện các chỉ số sinh so với V3 trên 100 đề.

V11 — thẻ lớp bài học. 499 câu bài học được gán vào 40 lớp ngữ nghĩa để tăng khả năng tái sử dụng cấu trúc. Prefix của 70% mẫu causal có thêm `<moral_class>…</moral_class>`; 30% replay giữ prefix cũ. Bảy checkpoint từ bước 150–1.011 được đánh giá trên cùng 20 đề. Causal validation loss giảm 2,908→2,610, còn replay loss giữ 1,547; checkpoint bước 600 có điểm sàng lọc cao nhất trong V11 nhưng vẫn thấp hơn V3.

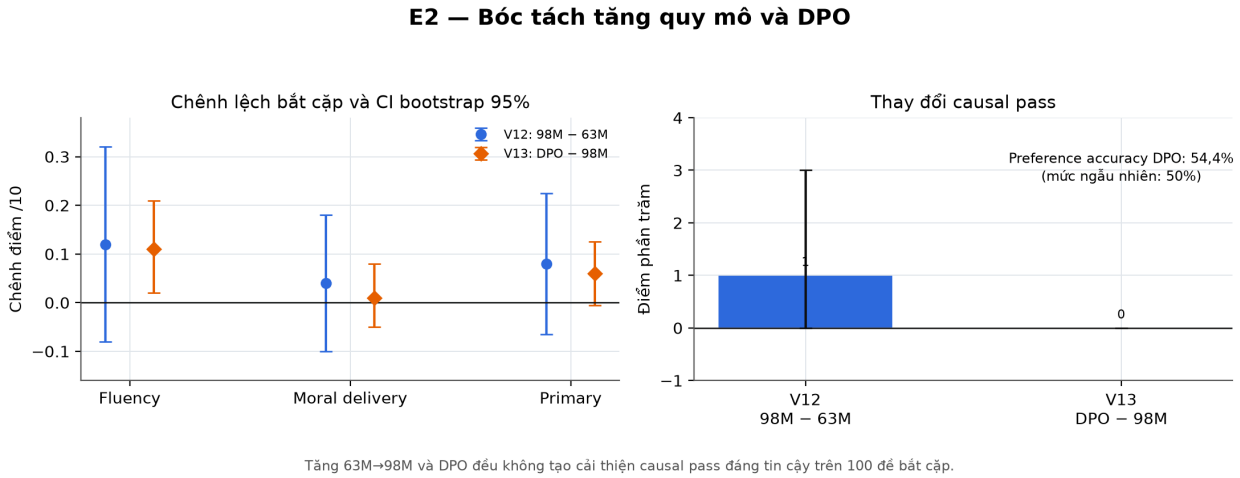
Thí nghiệm loại trừ dùng **cùng trọng số bước 600**, chỉ thay việc có hay không truyền thẻ lớp. Khi có thẻ, thân truyện giảm còn 90,8 từ, resolved-ending 5% và primary 2,83. Khi bỏ thẻ, độ dài trở lại 247,8 từ, resolved-ending 80% và primary 3,65, gần V3 (252,2 từ; 85%; 3,75). Vì trọng số không đổi, khác biệt này được quy cho token điều khiển: `<moral_class>` chọn style ngắn của corpus teacher thay vì cung cấp một plan ngữ nghĩa có thể tái sử dụng.



Hình 16: E2: loss validation của V11 và thí nghiệm loại trừ cùng checkpoint bước 600 khi có hoặc bỏ thẻ lớp bài học.

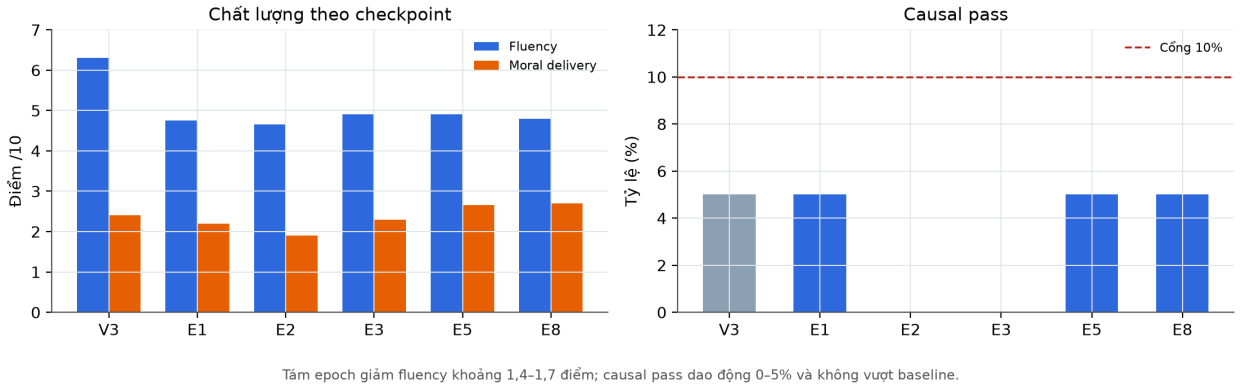
V12 — thí nghiệm loại trừ về quy mô. Hai mô hình 62.985.984 và 98.425.344 tham số được huấn luyện độc lập với cùng tokenizer, thứ tự dữ liệu, seed, batch, dropout, lịch LR và curriculum V2→V3. Khác biệt duy nhất là số khối decoder: 7 so với 12. Trên 100 đề bắt cặp, 98M tăng fluency 0,12 [–0,08; 0,32], primary 0,08 [–0,065; 0,225] và causal-pass một điểm phần trăm [0; 3]. Cận dưới của CI của causal-pass bằng 0, nên dữ liệu không hỗ trợ giả thuyết rằng mức tăng 63M→98M tự nó giải quyết được causal steering.

V13 — DPO khớp độ dài. Tập DPO gồm 391 cặp train và 103 cặp validation. `Chosen` là truyện teacher strict-pass; `rejected` là lỗi causal của V12-98M trên đúng prompt. Độ dài trung bình được khớp ở 268,6 và 276,7 token để tránh mô hình học preference qua độ dài. Sau 39 bước tối ưu, độ chính xác phân biệt chosen/rejected trên validation đạt 54,4%, gần mức ngẫu nhiên 50%. Trên 100 đề, fluency tăng 0,11 [0,02; 0,21], primary tăng 0,06 [–0,005; 0,125], nhưng causal-pass thay đổi 0. DPO cải thiện nhẹ chất lượng bề mặt mà không điều khiển được liên kết đang thiếu.



Hình 17: E2: chênh lệch bắt cặp của thí nghiệm tăng 63M→98M và DPO trên 100 đề. Thanh sai số là CI bootstrap 95%.

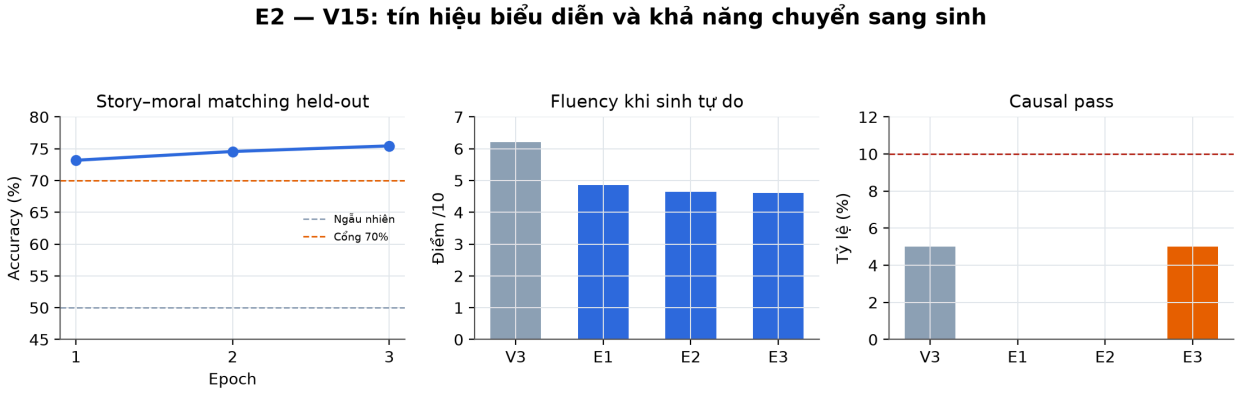
V14 — tăng mức tiếp xúc với dữ liệu nhân quả. V14 loại hoàn toàn replay và học tám epoch trên 13.270 truyện nhân quả, giữ checkpoint tại epoch 1, 2, 3, 5 và 8. Mốc V3 có fluency 6,30 và causal-pass 5%. Các checkpoint V14 có fluency 4,65–4,90, moral-delivery 1,90–2,70 và causal-pass 0–5%; strict-pass bằng 0 ở mọi mốc. Tăng số epoch không tạo xu hướng cải thiện causal ổn định, trong khi fluency giảm ít nhất 1,4 điểm. Với corpus và khởi tạo này, causal-LM objective ưu tiên khớp token của tập hẹp hơn là giữ phân bố ngôn ngữ rộng của V3.



Hình 18: E2: chất lượng và causal-pass của V14 qua các checkpoint của tám epoch causal-only.

V15 — loss phụ liên kết story–moral. V15 thêm đầu phân loại nhị phân trên trạng thái cuối để phân biệt moral đúng với moral hoán đổi; trọng số loss phụ là 0,5 và prompt phụ không xuất hiện khi sinh. Độ chính xác trên tập giữ lại tăng 73,18%→75,44%, cao hơn mức ngẫu nhiên và vượt mốc 70% dùng để kiểm tra khả năng biểu diễn. Tuy nhiên, fluency giảm từ 6,20 của V3 còn 4,60–

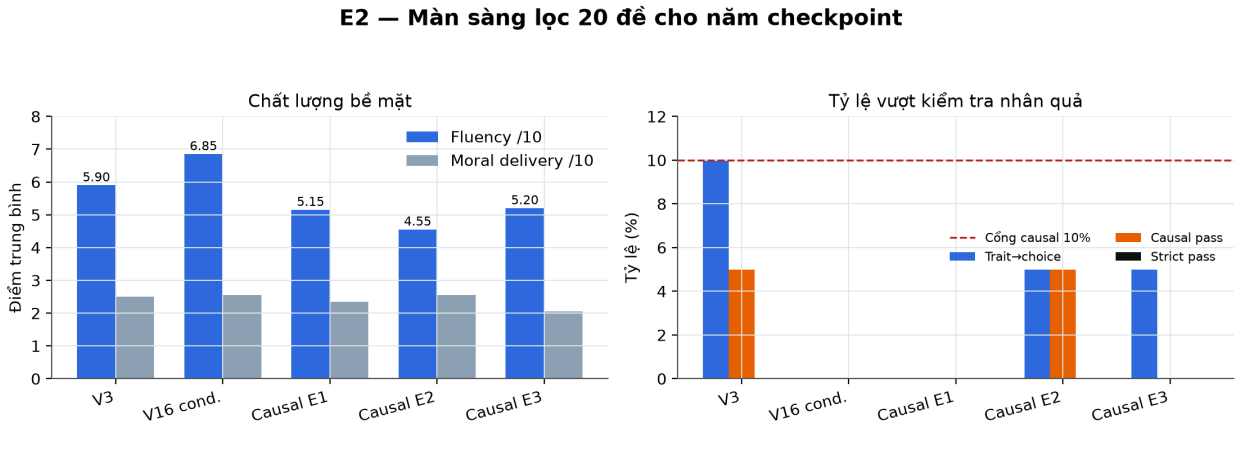
4,85; causal-pass chỉ 0–5% và strict-pass vẫn 0%. Mô hình mã hóa được tín hiệu ghép cặp ở cuối truyện nhưng tín hiệu này không đủ định hướng quá trình chọn token ở các bước trước.



Hình 19: E2: auxiliary head của V15 học được story–moral matching nhưng không cải thiện sinh tự do.

V16 — tăng ngân sách tiền huấn luyện. V16 quay lại 63M với khởi tạo ngẫu nhiên, tăng corpus tiền huấn luyện từ 200.000 lên 500.000 truyện trước khi chạy lại pha điều kiện hóa và ba epoch chỉ dùng dữ liệu nhân quả. Vòng sàng lọc cố định dùng 20 đề, temperature 0,2, top-p 0,9, repetition penalty 1,3 và tối đa 420 token. So với V3, checkpoint `v16-conditioned` tăng fluency 5,90→6,85 và giữ moral-delivery gần như ngang 2,50→2,55. Trait-drives-choice, causal-pass và strict-pass của checkpoint này đều 0%.

Ba checkpoint causal đạt fluency 5,15; 4,55; 5,20 và causal-pass tối đa 5%. Để chạy đủ 100 đề, cấu hình phải có causal-pass ≥10% và fluency không giảm quá một điểm; không cấu hình nào đạt yêu cầu này nên không chạy đánh giá đầy đủ. `v16-conditioned` được chọn làm mô hình dùng để chạy vì có chất lượng truyện tốt nhất trong V16, không phải vì đạt mục tiêu liên kết nhân quả.



Hình 20: E2: kết quả vòng sàng lọc trên 20 đề cho V3, V16-conditioned và ba checkpoint causal.

Kết luận E2. Những cải thiện rõ nhất của E2 nằm ở biểu diễn token, chất lượng ngôn ngữ và khả năng bám đúng trường đầu vào. Gói sửa V1→V2 loại bỏ lỗi vỡ từ, tăng Distinct-1/2 và giảm Self-BLEU mà gần như không làm thay đổi độ dễ đọc. Prompt masking ở V3 nâng exact-character từ 18% lên 65%, exact-moral từ 17% lên 86%, exact-both từ 3% lên 55% và tỷ lệ kết thúc bằng `</story>` từ 0% lên 100%. V16 cho thấy tăng dữ liệu tiền huấn luyện từ 200.000 lên 500.000

truyện tiếp tục cải thiện fluency. Như vậy mô hình 63M học được ranh giới từ, hình thức prompt và phân bố văn phong khi mục tiêu huấn luyện cung cấp tín hiệu trực tiếp ở cấp token.

Các phép đo chuỗi sự kiện lại cho kết quả khác. V3 dùng đúng nhân vật làm tác nhân ở 96% mẫu nhưng trait→choice chỉ đạt 1% và plot-entails-moral bằng 0%. V10 giảm causal validation loss từ 3,404 xuống 2,968 mà causal-pass vẫn không khác V3; V15 đạt 75,44% accuracy ghép story với moral nhưng không chuyển tín hiệu biểu diễn đó thành lựa chọn token khi sinh. Ba năng lực này cần được tách riêng: nhận biết quan hệ story-moral, tái tạo target khi học có teacher forcing, và tự xây dựng chuỗi conflict→choice→consequence trong rollout. E2 cải thiện hai năng lực đầu ở một số cấu hình nhưng chưa cải thiện ổn định năng lực thứ ba.

Các kết quả tiếp theo giúp thu hẹp thêm các giả thuyết nguyên nhân. Replay giữ được văn phong nhưng không tăng causal-pass; thẻ `<moral_class>` chọn kiểu truyện ngắn của teacher thay vì cung cấp một dàn ý hữu ích; huấn luyện chỉ bằng dữ liệu nhân quả tới tám epoch làm giảm fluency mà không tạo xu hướng causal tăng; DPO chỉ đạt preference accuracy 54,4%; tăng riêng từ bảy lên mười hai layer cho chênh causal-pass một điểm phần trăm với cận dưới CI bằng 0. Vì vậy dữ liệu hiện tại không ủng hộ việc chỉ tăng nhẹ depth, số epoch hay thêm một mục tiêu phụ không gắn với quá trình giải mã. Một hướng khả dĩ là giám sát trực tiếp các trạng thái kế hoạch hoặc dùng tín hiệu cấp chuỗi có thể tác động lên rollout, nhưng E2 chưa kiểm chứng các phương án đó nên không xem đây là kết luận thực nghiệm.

Kết quả cũng không thiết lập giới hạn phổ quát cho mô hình 63M. Các biến thể dùng một corpus, một họ mục tiêu huấn luyện và một dải quy mô hẹp 63M–98M; một kiến trúc khác, dữ liệu có liên kết nhân quả rõ hơn hoặc ngân sách lớn hơn có thể cho kết quả khác. Đóng góp chính của E2 là chỉ ra rằng loss thấp, khả năng bám đúng đầu vào cao và story-moral matching tốt vẫn không đủ chứng minh điều kiện đã chi phối diễn biến. Đánh giá sinh có điều kiện phải đo riêng các liên kết trait→choice, choice→outcome và plot→moral.

Trong vòng chung, E2 được chạy đúng định dạng hai trường `character + moral`, còn đề đánh giá chung chứa năm trường. Runner không truyền setting, challenge và outcome vào mô hình, nên điểm 3,18/10 phản ánh một hệ thống hai điều kiện khi bị đánh giá trên yêu cầu năm điều kiện. Điểm này phù hợp để đo mức tương thích của mô hình với giao diện chung, nhưng không phải phép kiểm định thay thế cho các bóc tách V1–V16. `v16-conditioned` được chọn vì có chất lượng ngôn ngữ tốt nhất trong họ V16; lựa chọn này không đồng nghĩa checkpoint đã đạt liên kết nhân quả.

2.4 E3 — So sánh vị trí LoRA trên SmolLM2-135M — Nguyễn Công Thanh (20252610M)

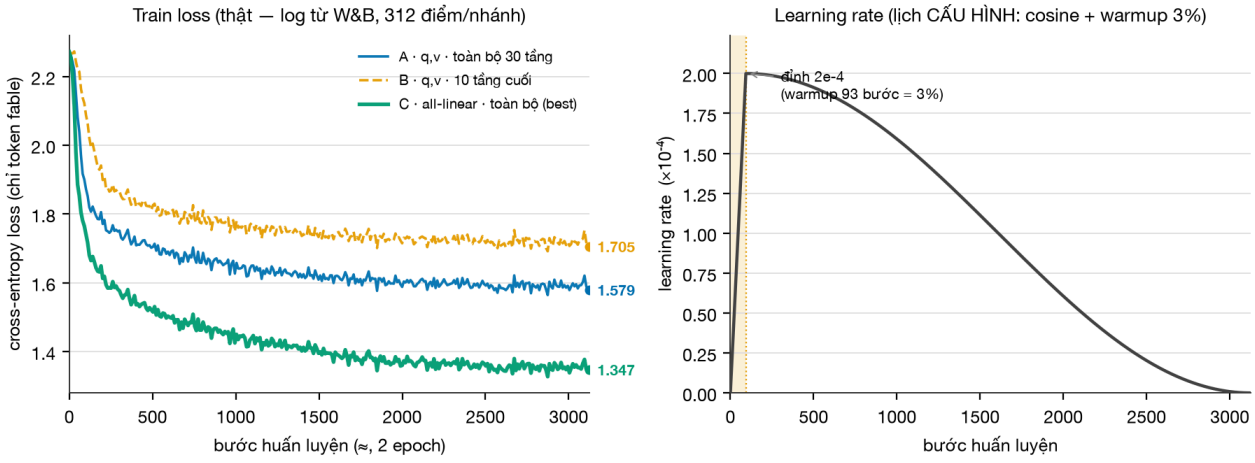
Ba cấu hình LoRA được so sánh trên cùng nền SmolLM2-135M, cùng dữ liệu và cùng ngân sách huấn luyện. Biến được thay đổi là vị trí tầng và mô-đun được gắn adapter.

Dữ liệu và mục tiêu. Tập con 50.000 mẫu TF1 được lấy bằng cách xáo trộn theo luồng với bộ đệm 10.000, seed 42. Cách lấy mẫu được cố định và giống nhau giữa các nhánh, nhưng gần với việc "xáo nhẹ phần đầu" hơn là lấy mẫu đều trên toàn corpus. `system_message + prompt` là phần điều kiện, `fable` là phần truyện; mọi token điều kiện bị mask `-100`, loss chỉ tính trên token truyện và token kết thúc. Mỗi nhánh học 2 epoch với ngữ cảnh 512 token. Tập giữ lại cố định gồm 500 hàng.

Kiến trúc và LoRA. SmolLM2-135M là mô hình decoder kiểu Llama với đúng 134.515.008 tham số: embedding/output head dùng chung vocabulary 49.152 token, 30 khối hidden 576, GQA 9 query head/3 KV head và MLP SwiGLU `576 → 1.536 → 576`. Mô hình hỗ trợ ngữ cảnh 8.192 token, còn thí nghiệm cố định chuỗi ở 512 token. Mô hình nền được đóng băng; LoRA chỉ học cập nhật hạng thấp cho các ma trận được chọn. Cả ba nhánh giữ r=16, α=32, dropout 0,05:

- A: `q_proj,v_proj` ở toàn bộ 30 layer, khoảng 0,92M tham số;
- B: cùng hai projection nhưng chỉ layer 20–29, khoảng 0,31M;
- C: `q,k,v,o,gate,up,down` ở toàn bộ layer, khoảng 4,88M, tức 3,5% model.

AdamW dùng LR đỉnh `2e−4`, cosine decay, warmup 3%, bf16 trên một GPU Colab L4, batch 16 × gradient accumulation 2 = 32, khoảng 3.125 bước/nhánh (≈1.563 bước/epoch × 2 epoch). Loss huấn luyện thực tế của cả ba nhánh được lấy lại từ log W&B (312 điểm/nhánh); learning rate tuân theo lịch cosine trong cấu hình — được xác định bởi công thức warmup 3% + cosine decay về 0, đỉnh 2e-4. Hệ thống tổng hợp không giữ log LR theo bước, nên phần LR trong hình là lịch theo cấu hình (đúng với scheduler đã chạy), không phải đường đo thực tế.

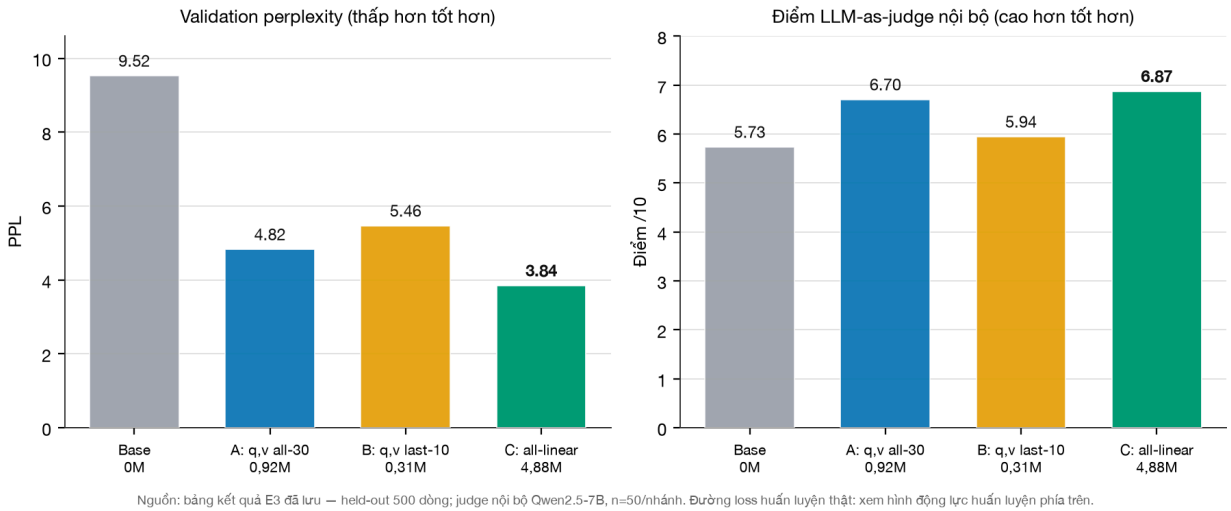


Hình 21: E3 — động lực huấn luyện. Trái: cross-entropy loss thật (chỉ trên token fable) của ba nhánh, phục hồi từ log W&B; thứ hạng hội tụ C (1,347) < A (1,579) < B (1,705) trùng thứ hạng perplexity held-out, và `exp` của loss cuối (3,85 / 4,85 / 5,50) gần khớp perplexity held-out (3,84 / 4,82 / 5,46) — dấu hiệu ít overfit. Phải: lịch learning-rate cấu hình (cosine, warmup 3% ≈ 93 bước, đỉnh 2e-4 rồi giảm về 0).

Perplexity và khả năng so sánh. Perplexity trên tập giữ lại được tính bằng `exp(mean cross-entropy)` trên 500 mẫu cố định, theo teacher forcing; loss chỉ cộng trên token fable (token điều kiện bị mask `−100` nên không vào mẫu số). Vì cả ba nhánh dùng chung tokenizer GPT-2 BPE của SmolLM2 (49.152 token) và chung cách mask, perplexity có thể so sánh trực tiếp và công bằng *trong phạm vi E3*. Tuy nhiên, perplexity tính trên token nên không thể so trực tiếp với E1 (BPE 12k), E2 (Metaspace BPE 16k) hay E4/E5 (Llama BPE 128k) vì mẫu số token khác bản chất. Đây chính là lý do mọi so sánh liên nhóm phải dùng giám khảo LLM chung trên cùng bộ đề (§4), thay vì đặt cạnh các perplexity khác tokenizer.

Kết quả trên tập giữ lại và điểm chấm.

Nhánh	Tầng	Mô-đun	PPL nội bộ	Điểm nội bộ
Nền	—	—	9.52	5.73
A	toàn bộ	chú ý q/v	4.82	6.70
B	1/3 tầng cuối	chú ý q/v	5.46	5.94
C	**toàn bộ**	**mọi lớp tuyến tính, chú ý + MLP**	**3.84**	**6.87**



Hình 22: E3: thí nghiệm loại trừ vị trí LoRA theo perplexity trên tập giữ lại (trái, thấp hơn tốt hơn) và điểm giám khảo nội bộ Qwen2.5-7B (phải, cao hơn tốt hơn); nhánh C dẫn đầu cả hai thước đo. Màu mỗi nhánh khớp với hình động lực huấn luyện phía trên.

PPL và điểm chấm nội bộ Qwen2.5-7B (n=50/nhánh) đều cho cùng thứ tự C > A > B > nền. So sánh A/B cho thấy phủ toàn bộ tầng tốt hơn chỉ đặt ở tầng cuối. So sánh A/C cho thấy mở rộng sang MLP quan trọng hơn chỉ tăng mô-đun chú ý. Tập sinh chẩn đoán có 100 truyện cho mỗi nhánh với temperature 0,8, top-p 0,9, repetition penalty 1,3; điểm chấm dùng 50 truyện đầu, greedy và chấm bốn trục. Adapter C được merge, xuất GGUF Q8_0 khoảng 138MB và đăng ký Ollama.

Kết luận E3. Trong cùng ngân sách huấn luyện, vị trí đặt LoRA ảnh hưởng rõ đến chất lượng thích nghi của SmolLM2-135M. Nhánh B chỉ gắn q/v ở một phần ba số tầng cuối đạt PPL 5,46, kém nhánh A gắn q/v trên toàn bộ tầng ở mức 4,82. Khi giữ phạm vi toàn bộ tầng và mở rộng adapter sang các phép chiếu MLP, nhánh C đạt PPL 3,84 và điểm judge 6,87, cao nhất trong ba nhánh. Kết quả hỗ trợ hai nhận định trong phạm vi E3: cập nhật xuyên suốt chiều sâu tốt hơn chỉ sửa các tầng cuối, và độ phủ mô-đun attention + MLP hiệu quả hơn attention-only cho tác vụ này.

Perplexity và điểm chấm không hoàn toàn tương đương. Nhánh B nhận được phần lớn mức giảm PPL so với mô hình nền nhưng mức bám đề 4,78 lại thấp hơn mức 5,08 của mô hình nền. Ngược lại, C dẫn đầu về grammar, moral clarity, adherence và overall; A dẫn đầu về creativity và Flesch. Do đó PPL phù hợp để đo mức khớp phân bố token held-out, nhưng không đủ để chọn adapter cho một tác vụ có ràng buộc. Các chỉ số diversity cũng phải được đọc cùng coherence: output nền hỗn loạn có thể tạo Distinct cao và Self-BLEU thấp mà không tạo thành truyện sử dụng được.

Thiết kế E3 chưa hoàn thành ma trận 2×2 vì thiếu cấu hình `all-linear × last-third`; đồng thời mỗi nhánh chỉ có một seed và giám khảo chưa được chấm lại. Vì vậy chưa thể tách hoàn toàn hiệu ứng vị trí tầng khỏi số lượng mô-đun và tổng dung lượng adapter, cũng không nên diễn giải các chênh lệch nhỏ như hiệu ứng phổ quát. Kết luận vững nhất là, trong ba cấu hình đã chạy, nhánh C cung cấp phân bổ adapter tốt nhất với khoảng 3,5% trọng số trainable.

Trong baseline vòng chung v1, E3 đạt 2,81/10 — nằm cùng dải hẹp 2,81–3,30 với E1 (3,30) và E2 (3,18), tách biệt rõ với E4/E5 (9,20 và 8,44). Runner v1 chỉ truyền phần đề, trong khi adapter được train với `system_message + prompt`, khiến prompt-adherence v1 xuống 1,44. Runner v2 đã gửi lại đúng system message và prompt; trên 25 đề, E3 đạt **3,13/10** (grammar 4,76; creativity 3,48; moral clarity 2,24; prompt adherence 2,04; CI [2,95; 3,31]). Mức tăng overall chỉ **+0,32**, nên bản sửa đã khắc phục đường vào nhưng không biến checkpoint thành một mô hình kể chuyện khác. Không

nên quy toàn bộ chênh lệch 2,81 → 3,13 cho system message vì v2 đồng thời sinh lại đầu ra và dùng rubric judge đã bỏ điều kiện chấm literal `Moral:`. Phần chi phối còn lại là các yếu tố cấu trúc đồng thời khác nhau giữa năm hướng: dung lượng mô hình 135M so với 3B của E4/E5, việc E3 là mô hình pretrain được tinh chỉnh nhẹ bằng LoRA trên 50k mẫu (so với E1/E2 huấn luyện đầy đủ từ đầu trên corpus fable), cùng khác biệt về dữ liệu tiền huấn luyện và giao diện điều kiện. Đúng như phần Tóm tắt đã lưu ý, chênh lệch điểm tổng hợp không quy trực tiếp cho số tham số vì các hướng khác nhau đồng thời ở nhiều chiều. Vì vậy điểm chung đo artifact E3 trên giao diện triển khai thống nhất, còn xếp hạng C > A > B > base chỉ có giá trị trong giao thức nội bộ E3. `tsv3-smollm135-best` (nhánh C) được chọn làm đại diện vì dẫn đầu cả PPL và overall trong phép so sánh có đối chứng của hướng này.

2.5 E4 — Llama 3.2 3B với kiểm soát đầu ra — Nguyễn Thị Phương Liên (20252130M)

Bảy cấu hình trên Llama 3.2 3B được so sánh: mô hình nền, SFT-clean-3k, Failure-LoRA 300 mẫu, prompt nghiêm ngặt, prompt kết hợp hậu xử lý, Base + Repair và Fluency-SFT 10k.

Kiến trúc và giao diện sinh. Hệ thống đại diện dùng trực tiếp Llama 3.2 3B Instruct Q4_K_M, gồm đúng 3.212.749.824 tham số, 28 khối với kích thước ẩn 3.072, GQA 24 query head/8 KV head, MLP SwiGLU 8.192 và Llama BPE 128.256 token. Mô hình gốc hỗ trợ ngữ cảnh 131.072 token nhưng bộ chạy chỉ dùng 2.048 token. Đầu vào gồm system prompt về truyện trẻ em và user prompt chứa năm trường; đầu ra đầu tiên là assistant message tối đa 400 token. Validator kiểm tra hình thức và độ dài; nếu phát hiện lỗi nghiêm trọng, cùng mô hình nhận thêm bản nháp và sinh lại tối đa 500 token. Cuối cùng hệ thống chuẩn hóa đúng một dòng `Moral:`. Vì vậy đầu ra báo cáo là sản phẩm của một quy trình bao quanh mô hình nền, không phải đầu ra của một checkpoint fine-tune mới.

Tập dữ liệu thích nghi.

- Failure-LoRA (tên artifact gốc) có 300 mẫu: 24 sai lệch quan sát trên benchmark và 276 mẫu TF1 có đầu ra đích đúng, gắn cùng hệ phân loại. Chia 270/30. Các nhãn sai lệch có thể chồng nhau: 177 thiếu/rỗng bài học, 117 kết thúc không sạch, 187 bài học lệch, 59 thiếu outcome. Công thức huấn luyện được tài liệu hóa là QLoRA 4-bit trên Llama 3.2 3B, LoRA r=16/α=16 trên bảy projection, context 1.024, batch hiệu dụng 8, 3 epoch, LR `1e-4`, warmup 5%, fp16 và gradient checkpointing.
- Fluency-SFT-v1 quét 18.970 hàng TF1 và nhận 10.000; chia 9.000/1.000 với seed 42. Lọc 110–280 từ nhưng phân bố được nhận thực tế là 212–280, trung bình 264,3 từ và điểm chất lượng heuristic 8,67/10. Lý do loại chính: quá dài 5.556, câu dài 2.722, không an toàn 2.092, nhiều moral 624, nhiều câu dài 280, lặp 13 và meta-text 4.

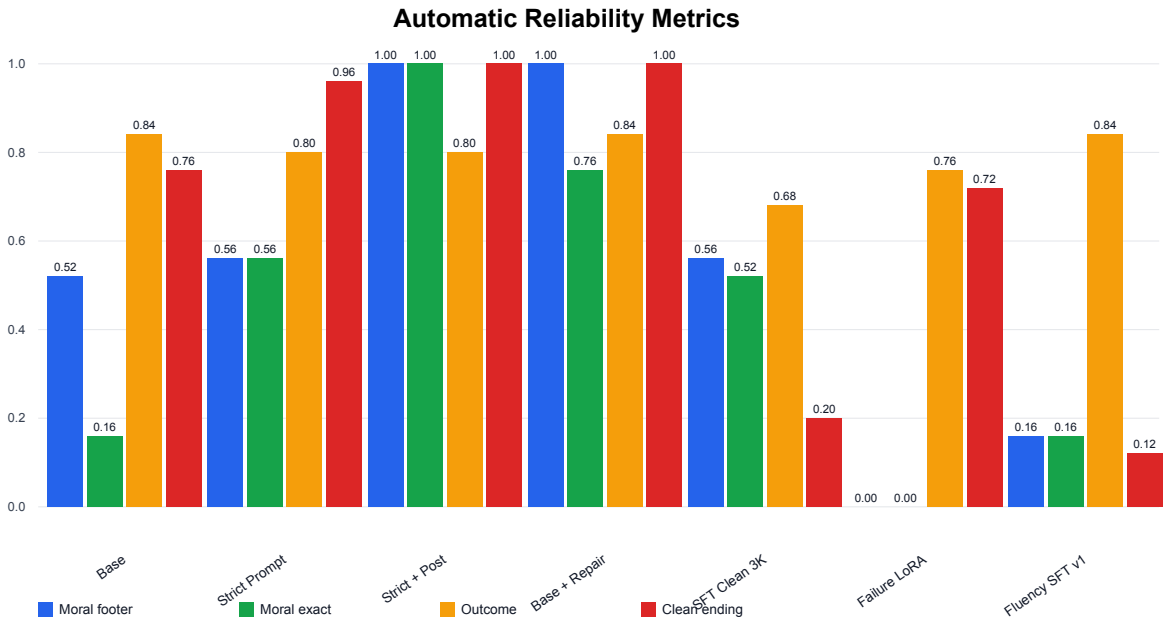
Kho mã nguồn không chứa notebook/checkpoint `trainer_state` của SFT-clean-3k, Failure-LoRA hay Fluency-SFT-v1. Vì vậy cấu hình trên là thông tin được bàn giao cho Failure-LoRA; báo cáo **không thể xác nhận** thời gian huấn luyện, đường loss/LR thực chạy hoặc gán nó cho hai lần SFT còn lại. Đây là thiếu sót cần bổ sung từ artifact Kaggle nếu muốn tái lập train.

Quy trình Base + Repair. Mô hình nền sinh một lần với seed 5410. Bộ kiểm tra phân biệt lỗi có thể sửa bằng luật với lỗi nghiêm trọng. Hậu xử lý chuẩn hóa dòng `Moral:`; chỉ khi phát hiện lỗi nghiêm trọng mới gọi cùng mô hình để sinh lại. Tệp kết quả lưu cả `raw_story`, truyện cuối, hành động sửa, validation trước/sau và latency cộng thêm. Điều này quan trọng: phương án cuối là **một hệ thống có thể gọi model hai lần**, nên lượt đánh giá chung đã tính cả độ trễ và lỗi của lượt sửa.

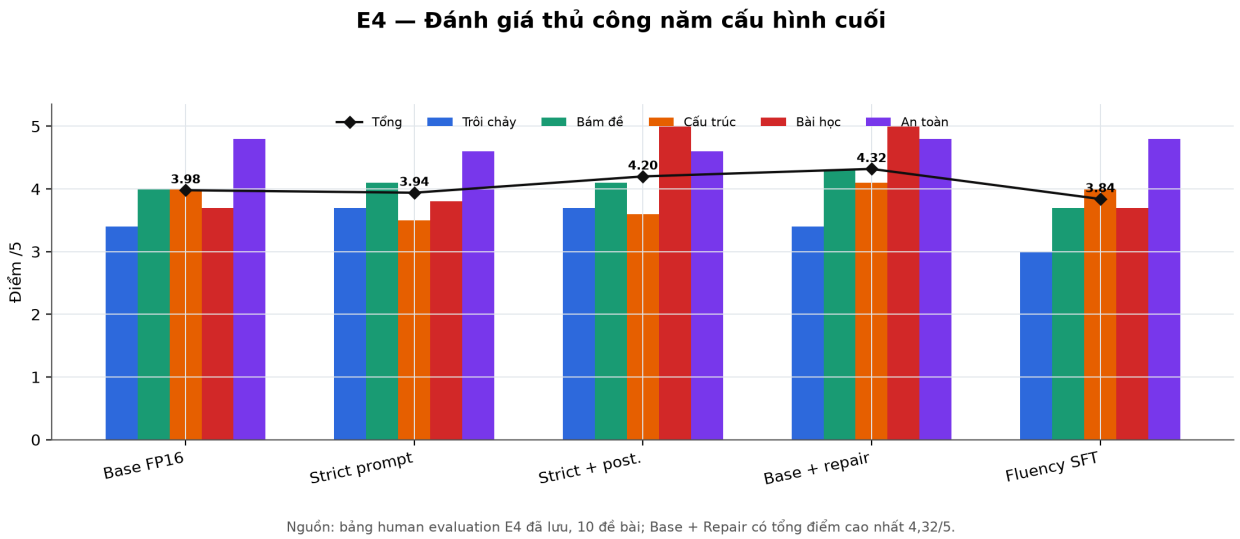
Bộ kiểm tra nội bộ gồm 25 đề bài. Kết quả tự động cho thấy `Strict + Postprocess` đạt tỷ lệ có dòng bài học, tỷ lệ khớp đúng bài học và tỷ lệ kết thúc sạch đều 1.00. Đánh giá thủ công trên 10 đề bài lại chọn `Base + Repair` là hệ thống cân bằng nhất:

Hệ thống	Trôi chảy	Bám đề bài	Cấu trúc	Bài học	An toàn	Tổng
Base FP16	3.40	4.00	4.00	3.70	4.80	3.98
Đề bài nghiêm ngặt	3.70	4.10	3.50	3.80	4.60	3.94
Đề bài + Hậu xử lý	3.70	4.10	3.60	5.00	4.60	4.20
Mô hình nền + Sửa lỗi	3.40	4.30	4.10	5.00	4.80	**4.32**
SFT độ trôi chảy v1	3.00	3.70	4.00	3.70	4.80	3.84

SFT-clean-3k làm yếu độ trôi chảy và phần kết. LoRA 300 không sửa được dòng bài học. LoRA 10k lọc kỹ vẫn có tỷ lệ `Moral:` rỗng 0,76, clean-ending 0,12 và đạt các chỉ số thấp hơn `Base + Repair`. Base + Repair tạo đầu ra cho 25/25 đề, dòng Moral cuối truyện 1,00, exact moral 0,76, outcome coverage 0,84, clean-ending 1,00; độ dài trung bình 216,8 từ và latency trung bình 81.575 ms.



Hình 23: E4: độ tin cậy tự động của bảy cấu hình trên cùng 25 đề bài nội bộ. Các chỉ số phản ánh hợp đồng đầu ra và độ phủ, không thay thế đánh giá ngữ nghĩa của con người.



Hình 24: E4: đánh giá thủ công năm cấu hình cuối trên 10 đề bài. Base + Repair đạt tổng điểm trung bình 4,32/5 và đứng đầu về cân bằng giữa bám đề, cấu trúc, bài học và an toàn.

Hai hình cho thấy một khác biệt về phương pháp: `Strict + Postprocess` có thể đạt 100% ở các kiểm tra định dạng xác định, nhưng `Base + Repair` được người chấm xếp cao hơn về chất lượng tổng thể. Đóng góp của E4 nằm ở việc kiểm soát toàn hệ thống; không thể suy từ tỷ lệ footer hoặc exact-moral rằng checkpoint đã học suy luận nhân quả tốt hơn.

Kết luận E4. E4 cho thấy các lỗi của mô hình nền 3B không thuộc cùng một loại và không cần cùng một cơ chế sửa. Prompt nghiêm ngặt cải thiện exact-character và kết thúc sạch; hậu xử lý xác định bảo đảm đúng một dòng `Moral:`; repair chỉ được gọi khi validator phát hiện lỗi nghiêm trọng. Cấu hình Base + Repair đạt 4,32/5 trong đánh giá thủ công nội bộ, cao hơn Strict + Postprocess 4,20 và Fluency-SFT 3,84. Trong vòng chung, hệ thống đạt 9,20/10 và đứng đầu năm hướng. Các kết quả nhất quán ở chỗ kiểm soát tại thời điểm suy luận tăng độ tin cậy mà vẫn giữ năng lực kể chuyện của mô hình nền.

Ba thử nghiệm fine-tuning đều cho kết quả không thuận lợi. SFT-clean-3k làm giảm độ trôi chảy, cấu trúc và chất lượng kết thúc; Failure-LoRA 300 không sửa được dòng bài học mục tiêu; Fluency-SFT trên 10.000 mẫu đã lọc vẫn có `Moral:` rỗng ở 76% đầu ra và chỉ đạt clean-ending 12%. Kích thước dữ liệu lớn hơn vì vậy không đủ nếu target format, phân bố độ dài hoặc template assistant chưa khớp chặt với giao diện sinh. Những kết quả này không chứng minh SFT hay LoRA kém hiệu quả nói chung; chúng cho thấy ba công thức dữ liệu và mục tiêu huấn luyện cụ thể của E4 không vượt được quy trình dùng mô hình nền.

So sánh đánh giá tự động và đánh giá thủ công cũng xác định phạm vi của từng chỉ số. Strict + Postprocess có thể đạt tuyệt đối ở moral footer và clean ending vì đây là các thuộc tính kiểm tra được bằng quy tắc, nhưng người chấm vẫn ưu tiên Base + Repair về bám đề, cấu trúc và chất lượng tổng thể. Ngược lại, một điểm exact-moral cao không chứng minh diễn biến đã sử dụng bài học theo quan hệ nhân quả. Trong ablation chung, repair tăng tỷ lệ bài học đúng nguyên văn từ 20% lên 100%, nhưng trait→choice giữ 92% và choice→outcome giữ 100%. Các liên kết cốt truyện đã tồn tại trong bản raw; repair chủ yếu thực thi hợp đồng đầu ra và sửa sai lệch cục bộ.

Đóng góp của E4 vì vậy nằm ở cách chọn biện pháp theo loại lỗi: dùng hậu xử lý cho ràng buộc cú pháp xác định, dùng validator + rewrite cho lỗi nội dung phát hiện được, và chỉ fine-tune khi có dữ liệu đủ mạnh để thay đổi hành vi phân bố. Đơn vị đánh giá phải là toàn bộ quy trình, không phải checkpoint nền. Kết luận còn bị giới hạn bởi 25 đề tự động, 10 đề chấm tay và việc thiếu trainer

state của các nhánh fine-tune; ngoài ra Base + Repair dùng thêm một lượt gọi mô hình ở 5/25 đề nên không giữ cố định chi phí suy luận với các hệ thống sinh một lượt.

2.6 E5 — QLoRA và lượng tử hóa Llama 3.2 3B — Nguyễn Đình Lê Hoàng (20252737M)

Áp dụng QLoRA rank 16 qua Unsloth lên toàn bộ phép chiếu attention và MLP của Llama 3.2 3B, rồi so sánh một với ba epoch; artifact cuối được lượng tử hóa GGUF Q4_K_M.

Dữ liệu. Notebook thực thi `train[:1000]` từ TF1 rồi `train_test_split(test_size=0.1, seed=42)`, tức lấy 1.000 hàng đầu nguồn rồi xáo/chia 900/100; câu "lấy mẫu ngẫu nhiên 1.000" trong báo cáo thành viên không khớp với code. `system_message`, `prompt`, `fable` được ghép bằng chat template Llama 3. `train_data.json` và `val_data.json` giữ lại 900/100 hàng. Không có kiểm tra loại prompt chung tương lai khỏi tập này ngoài so hash chính xác.

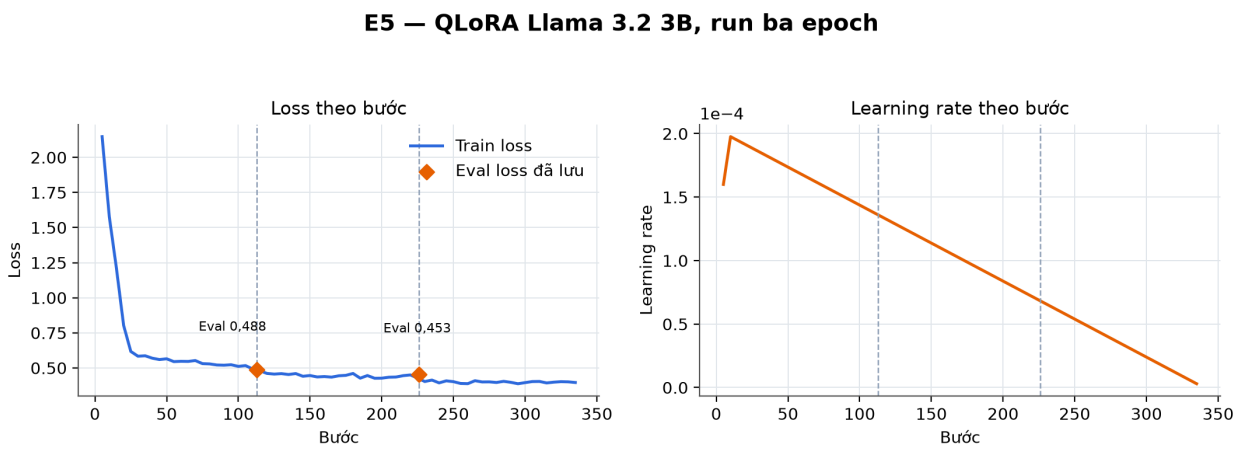
Cấu hình. Base là `unsloth/Llama-3.2-3B-Instruct-bnb-4bit`: 28 khối hidden 3.072, GQA 24 query head/8 KV head, MLP SwiGLU 8.192, vocabulary 128.256 và output head dùng chung token embedding. Kiến trúc gốc hỗ trợ 131.072 token; notebook giới hạn train ở 2.048 và đặt `load_in_4bit=True`. Dữ liệu được đóng gói bằng chat template Llama 3 theo chuỗi `system → user → assistant → <|eot_id|>`. Notebook không cấu hình collator chỉ tính loss trên completion, nên cross-entropy được áp dụng lên toàn bộ chuỗi chat đã đóng gói, không chỉ riêng token truyện. LoRA r=16, α=16, dropout 0, gắn vào `q,k,v,o,gate,up,down`; Unsloth gradient checkpointing; batch 4 × accumulation 2 = 8; warmup 5 bước; LR đỉnh `2e-4`; fp16 hoặc bf16 tùy T4 hỗ trợ. Có 24.313.856 tham số được huấn luyện, tương đương 0,75% mô hình. Hai lần chạy cho phép xem xét ảnh hưởng của số epoch và kiểm tra quy trình xuất GGUF Q4_K_M → Ollama → chế độ So sánh:

Phiên bản	Chu kỳ	Bước	Thời gian	Mất mát huấn luyện cuối	Sản phẩm
Fable-300	1	~113	~15 phút	báo cáo thành viên: ~0,492	GGUF Q4_K_M
Fable-1000	3	339	~47 phút	báo cáo thành viên: 0,514	GGUF Q4_K_M

Quá trình tối ưu qua ba epoch. `trainer_state.json` ghi nhận cửa sổ loss giảm nhanh rồi phẳng:

Bước/epoch	Train loss window	LR	Validation loss
5 / 0,04	2,147	`1,60e-4`	—
10 / 0,09	1,578	`1,98e-4`	—
110 / 0,98	0,492	`1,38e-4`	—
113 / 1,00	—	—	0,4883
225 / 2,00	0,428	`6,89e-5`	—
226 / 2,00	—	—	0,4528
335 / 2,97	0,396	`2,99e-6`	—

LR sau warmup giảm gần tuyến tính về 0. Log checkpoint không có bản ghi đánh giá ở bước 339/epoch 3. Vì thế con số validation 0,451 trong báo cáo gần với val epoch 2 nhưng không được xác nhận là "val cuối"; con số train 0,514 cũng không phải window cuối 0,396. Cần giữ tách bạch hai nguồn và không trộn lẫn các định nghĩa. Cả hai mô hình đã được lượng tử hóa khoảng 2GB; Modelfile dùng temperature 0,8, top-p 0,9, repetition penalty 1,1 và ngữ cảnh 2.048.



Nguồn: checkpoint-339/trainer_state.json (67 điểm train, eval tại bước 113 và 226). Artifact không lưu eval tại bước 339.

Hình 25: E5: train loss, hai mốc validation được lưu và lịch tốc độ học của run QLoRA ba epoch. Artifact không có validation loss tại checkpoint bước 339.

Loss giảm mạnh trong khoảng 30 bước đầu rồi giảm chậm từ khoảng 0,6 xuống 0,4. Hai điểm validation 0,488 và 0,453 cùng xu hướng với loss huấn luyện và chưa cho thấy dấu hiệu phân kỳ đến cuối epoch 2. Tuy nhiên, vì không có validation ở epoch 3 và không có trainer state tương ứng cho run một epoch, các đường này không đủ để quy phần tăng chất lượng cho việc huấn luyện thêm hai epoch.

Kết luận E5. Lần chạy ba epoch cho thấy việc thích nghi và chạy cục bộ Llama 3.2 3B trong ngân sách phần cứng phổ thông. QLoRA chỉ cập nhật 24,31M tham số, tương đương 0,75% mô hình, hoàn tất 339 bước trong khoảng 47,3 phút trên Tesla T4; sau merge, artifact GGUF Q4_K_M khoảng 2GB chạy được bằng Ollama. Loss huấn luyện giảm mạnh ở đầu run rồi ổn định quanh 0,4; validation loss giảm từ 0,488 ở epoch 1 xuống 0,453 ở epoch 2 và chưa cho thấy phân kỳ tại mốc được lưu. Đây là bằng chứng về quá trình tối ưu ổn định và khả năng đóng gói, không tự nó là bằng chứng về chất lượng truyện.

So sánh một và ba epoch chưa tạo thành một thí nghiệm loại trừ đầy đủ. Artifact không giữ trainer state của run một epoch, run ba epoch không có validation tại bước 339, và báo cáo thành viên không lưu điểm chất lượng bắt cặp giữa hai checkpoint. Vì vậy không thể quy điểm cao của artifact cuối cho hai epoch bổ sung hoặc kết luận ba epoch tốt hơn một epoch. Tương tự, vòng chung không có một bản Llama 3.2 3B chưa QLoRA được chạy bằng chính codec E5; đóng góp riêng của adapter so với năng lực đã có của model nền chưa được cô lập.

Dù vậy, chất lượng ở cấp hệ thống của artifact cuối được xác nhận trực tiếp. E5 đạt 8,44/10 trên 25 đề, là mô hình sinh một lượt tốt nhất và chỉ thấp hơn pipeline E4 có validator/repair 0,76 điểm. Khi chuyển từ hai lên năm trường, độ phủ tăng 3,68/5 và điểm nhất quán với chuỗi sự kiện được yêu cầu tăng 7,28/10. Trong mười cặp counterfactual chỉ thay trait hoặc outcome, cả 10/10 cặp đều thay đổi lựa chọn hoặc cách giải quyết theo đúng hướng. Các phép đo này cung cấp bằng chứng mạnh hơn fluency đơn thuần rằng mô hình sử dụng tổ hợp điều kiện trong tập kiểm thử.

Kết quả E5 vì vậy hỗ trợ hai kết luận tách biệt: QLoRA + GGUF là một quy trình triển khai 3B khả thi với ít trọng số trainable, và artifact cuối giữ được điều kiện tốt khi sinh trực tiếp. Kết quả chưa xác định phần cải thiện đến từ QLoRA, số epoch hay mô hình nền. Để trả lời câu hỏi đó cần chạy base, checkpoint một epoch và checkpoint ba epoch trên cùng 25 đề, cùng codec, seed và decoding; sau đó chấm bắt cặp cả chất lượng tổng thể lẫn độ nhạy counterfactual.

2.7 Phân tích định tính các đầu ra

Các mẫu dưới đây được giữ nguyên tiếng Anh vì tác vụ đích là sinh truyện tiếng Anh. Bốn mẫu đầu đến từ **đề bài và cấu hình cục bộ khác nhau**, nên chỉ dùng để minh họa hành vi; mẫu E5 lấy từ lượt đánh giá chung để bổ sung đầu ra còn thiếu. So sánh trực tiếp chỉ dùng toàn bộ 125 truyện ở §4. Dấu […] là phần rút gọn khi trình bày, không phải token do mô hình sinh.

E1 · `slm-60m`. Prompt: *a clever skunk; flower field; rivalry in love; ancient enemies sign a pact; appearances can be deceiving.*

> In a sunny flower field, a clever skunk named Stinky loved to play among the colorful blooms. One day, while sniffing around, Stinky met a beautiful butterfly named Lovely. They became fast friends and spent their days playing together.
>
> But not everyone was happy about their friendship. A grumpy bear named Growler lived on the outskirts of the flower field. […] One day, Stinky saw Growler struggling to reach a sweet flower. “Let's work together,” Stinky said. […]
>
> To celebrate their new friendship, Stinky and Growler signed a pact on a piece of paper. “We will always look beyond our appearances,” Stinky said. “Appearances can be deceiving.” From that day on, Stinky and Growler played together, and the flower field became an even happier place.

Đầu ra giữ đúng bối cảnh, kết quả và bài học nhưng thay thử thách “rivalry in love” bằng xung đột về mùi cơ thể. Trường hợp này được phân loại là thay thế điều kiện và cho thấy độ tuân thủ phải được chấm theo từng trường, thay vì chỉ dò từ khóa.

E2 · `v16-conditioned`. Prompt: *a joyful goose*; moral: *Changing one's environment cannot change one's inherent nature.*

> In the heart of an enchanted grove, where sunbeams danced through leaves and wildflowers bloomed in every color, lived a joyful goose. Her feathers shone like polished jewels, and her honks echoed across the forest floor.
>
> One day, while exploring the grove's hidden glade, she stumbled upon a mysterious stone. As soon as she touched it, a strange curse fell upon her. From that moment on, whenever she tried to fly, she'd stumble. […] With newfound confidence, she spread her wings and soared above the grove. To everyone's surprise, she felt free!
>
> Moral: Changing one's environment cannot change one's inherent nature.

Đây là ví dụ điển hình của kết quả V16: văn trôi chảy nhưng diễn biến “đổi hoàn cảnh không đổi bản chất” chưa được chứng minh bằng lựa chọn/hệ quả. Bản raw còn kết thúc bằng `Moral: second chances reveals another` và lặp nhiều thẻ `</story>`; harness local đã thay moral bằng trường yêu cầu trong bản `story`. Runner global không làm việc đó: chỉ tách các thẻ đặc biệt và giữ nguyên nội dung do mô hình sinh.

E3 · `tsv3-smollm135-best`. Prompt: *a brave little turtle; quiet pond; sudden storm; animals work together; teamwork overcomes fear.*

> In the quiet pond, where water lilies swayed gently in the breeze and fish swam happily by, a brave little turtle lived among his friends… One day, dark clouds gathered over the pond as strong winds howled and loud thunderclaps rumbled… The clever rabbit, strong and swift, had been watching from a nearby rock. He suggested that they work together to save their friends… The two groups of creatures huddled closer and began working together…

Kho của nhóm chỉ giữ trích đoạn này, không giữ toàn bộ 100 đầu ra sinh từ kho mã nguồn. Đầu ra có cấu trúc ngụ ngôn nhưng xuất hiện lệch nhân vật và chuỗi nhiễu (`Figure 1`).

E4 · Base + Repair. Prompt p01: *a small turtle; a quiet pond; cross a busy road; friends help him cross safely; patience and teamwork matter.*

> In a peaceful pond, lived a little turtle named Terry. One sunny day, he decided that adventure called him to explore beyond the water's edge. As he made his way closer to where some tall trees stood guard near busy Roady Way, Terry realized it was impossible for just one tiny creature like himself to cross.
>
> […] Together with some frogs who climbed trees nearby for high ground view points and rabbits carrying sturdy vines on their backs that formed a rope bridge...the whole crew got to work making it possible! Under Terry's guidance, carefully constructed walkways allowed him the safe passage across Roady Way.
>
> Moral: When friends unite towards one goal with patience in harmony - there is nothing big or small they can't accomplish together as best of buddies.

Repair bảo đảm moral hiện diện và đúng ý, nhưng không tự sửa hết câu vụng, dấu ba chấm hay logic “frog climbed trees”. Điểm thủ công 4,32 là trung bình toàn 10 đề, không phải điểm riêng của mẫu này.

E5 · `llama3-fable-1000-q4`. Lượt global GJ20 yêu cầu một chú rùa thận trọng tìm đường mới qua vườn cây sau khi đường xe sụp:

> In a hillside orchard, where juicy apples grew on tall trees, lived a careful tortoise named Terry. Terry loved to walk along the usual cart path that wound its way through the orchard, carrying baskets of fresh fruit to the market.
>
> One sunny day, as the harvest was in full swing, disaster struck! The old cart path suddenly collapsed, and the fruit began to roll away. […] Taking a deep breath, Terry started to test a new route in small steps. […]
>
> Moral: Careful courage makes room for useful change.

Đây là đầu ra thật của checkpoint, không phải target trong `val_data.json`. Truyện có 240 từ trung bình trên 25 đề global; riêng GJ20 có 236 từ và được Gemma chấm 9,00.

3. Kết quả theo câu hỏi nghiên cứu

3.1 RQ1 — Ảnh hưởng của năng lực nền

E2 và E1 cung cấp bằng chứng về mô hình huấn luyện từ khởi tạo ngẫu nhiên. Cải thiện tokenizer, tăng token và tăng quy mô đều nâng chất lượng ngôn ngữ, nhưng hai mô hình vẫn không sử dụng ổn định tổ hợp điều kiện. E4–E5 kế thừa biểu diễn ngôn ngữ từ mô hình đã tiền huấn luyện nên sai số chủ yếu chuyển sang tuân thủ điều kiện, định dạng đầu ra và chất lượng thích nghi.

Do đó, tiền huấn luyện từ đầu và PEFT không phải hai phương pháp thay thế trực tiếp: phương pháp thứ nhất xây dựng biểu diễn nền, còn phương pháp thứ hai thích nghi biểu diễn đã có. Điểm nội bộ giữa hai nhóm không thể so sánh trực tiếp khi tokenizer, tập đề và giám khảo khác nhau.

3.2 RQ2a — Ảnh hưởng của dữ liệu và tối ưu hóa

- E2 sửa bộ tách từ rồi tăng tiền huấn luyện; dữ liệu nhân quả từ mô hình giáo viên vẫn chưa tạo được năng lực suy luận.
- E1 vừa tăng token vừa sửa chế độ dữ liệu; mở rộng lên toàn bộ TF1 là can thiệp mang lại cải thiện rõ nhất.
- E4 ghi nhận rằng 10k hàng đã lọc vẫn có thể học sai định dạng bài học.
- E3 giữ dữ liệu cố định để cô lập vị trí bộ chuyển đổi.
- E5 dùng 1k hàng và thay số chu kỳ, nhưng chưa có kết luận chất lượng để tách thiếu khớp với quá khớp.

Kết quả không hỗ trợ việc dùng số lượng mẫu làm đại diện trực tiếp cho chất lượng tín hiệu huấn luyện. Các báo cáo cần chỉ rõ định dạng, vùng tính loss, độ phủ trường và phân bố lỗi để phân biệt hiệu ứng dữ liệu với hiệu ứng tối ưu.

3.3 RQ2b — Vị trí đặt các tham số thích nghi

E1 tăng năng lực của toàn mô hình 30M → 60M và thu được lợi ích. E3 giữ mô hình nền cố định nhưng mở bộ chuyển đổi từ mô-đun chú ý sang chú ý + MLP và cũng thu được lợi ích. Ở E4/E5, mô hình nền 3B đã cung cấp chất lượng ngôn ngữ đủ cao; phần sai số còn lại liên quan chủ yếu đến dữ liệu thích nghi, hàm mục tiêu và kiểm soát đầu ra.

Hai kết quả dương cho thấy vị trí phân bổ tham số trainable phải phù hợp với nguồn sai số: tăng năng lực toàn mô hình khi biểu diễn nền còn yếu; mở rộng adapter sang MLP khi mô hình nền được đóng băng.

3.4 RQ4 — Đóng góp của lớp kiểm soát khi suy luận

Best-of-N của E1 và hậu xử lý/repair của E4 là hai can thiệp suy luận có cải thiện đo được. Best-of-N làm giảm phương sai lựa chọn; validator và repair xử lý lỗi định dạng hoặc vi phạm điều kiện có thể phát hiện. Trong cùng phạm vi ngân sách, nhiều thử nghiệm DPO, RAFT, GRPO, distillation, SFT và LoRA nhỏ không cải thiện chất lượng kỳ vọng hoặc làm giảm chất lượng.

Kết quả E3 loại trừ diễn giải “tinh chỉnh luôn không hiệu quả”: LoRA có hiệu quả khi dữ liệu, mô hình nền và vị trí adapter phù hợp. Kết luận trong phạm vi nghiên cứu là can thiệp trọng số phụ thuộc chất lượng tín hiệu, trong khi lỗi có đặc tả hình thức nên được so sánh với một baseline kiểm soát lúc suy luận.

3.5 Khả năng so sánh giữa các đánh giá nội bộ

Cấu hình	Dụng cụ nội bộ chính	Phạm vi kết luận
E1 · Lê Hải Triều (20252611M)	Qwen3-4B chấm 4 trục, hạt giống bắt cặp, n=45; đo nhiễu	xếp hạng các biến thể E1
E2 · Đào Đức Tùng (20252612M)	vòng sàng lọc 20 trường hợp, Gemma nội bộ + tiêu chí nhân quả	chọn điểm kiểm tra trong chuỗi V16
E3 · Nguyễn Công Thanh (20252610M)	PPL + Qwen2.5-7B, n=50/nhánh	xếp hạng vị trí LoRA
E4 · Nguyễn Thị Phương Liên (20252130M)	luật tự động 25 đề bài + người chấm 10 đề bài	xếp hạng các biến thể E4
E5 · Nguyễn Đình Lê Hoàng (20252737M)	loss + đánh giá nhanh chưa báo số	chưa đủ kết luận chất lượng

Bảng không có cột điểm tổng hợp vì các giá trị 8,96; 6,87; 6,85 và 4,32 được tạo bởi những thang đo khác nhau. Việc xếp hạng E1–E5 từ các điểm nội bộ sẽ vi phạm tính đồng nhất của phép đo.

4. Đánh giá chung và các thí nghiệm phân tích

4.1 Thiết lập và trạng thái thực nghiệm

Điểm nội bộ không được nhập vào kết quả thống nhất. Năm mô hình đại diện được nạp trực tiếp trên cùng máy Apple M4 Pro 24 GiB. Tổng cộng 125 truyện hợp lệ được sinh và chấm trong vòng đánh giá chung.

4.2 Tệp mô hình và môi trường chạy

Chặng	Artifact thực chạy	Backend
E1	`models/global-bench/slm-60m.gguf`	llama.cpp
E2	`runs/v16/artifacts/conditioning-mlx`	MLX-LM
E3	SmolLM2-135M + adapter C	Transformers/PEFT
E4	Base + Repair trên Llama 3.2 3B Instruct Q4	llama.cpp + validator/repair
E5	`llama3-fable-1000-q4.gguf`	llama.cpp

Ở E2, MLX-LM chỉ là backend suy luận cho `runs/v16/artifacts/conditioning-mlx` trong vòng đánh giá chung. Việc artifact được phục vụ bằng MLX không thay đổi framework đã dùng để huấn luyện checkpoint V16: phần huấn luyện vẫn chạy bằng PyTorch/Transformers trên Colab.

E2 dùng đúng định dạng huấn luyện `<char>…</char><moral>…</moral><story>` và chỉ nhận `character` cùng `teaching`; ba slot `setting`, `challenge` và `outcome` không có kênh biểu diễn trong artifact này. Bộ chạy chỉ bóc thẻ đặc biệt, không thay moral. E1 sinh phần truyện trực tiếp, `best_of_n`=1. E4 sinh bằng mô hình nền rồi chạy validator: 5/25 truyện bị viết lại, 19/25 cần chuẩn hóa dòng moral, tổng cộng 21/25 có ít nhất một hành động. E3 chạy mô hình nền và adapter rời bằng PEFT thay vì dựa vào một Ollama model chưa tồn tại trên máy. E5 dùng chat template nhúng trong GGUF.

4.3 Bộ đề đánh giá

`results/global_judge/global_prompts_v1.jsonl` chứa 25 đề mới với sáu trường `prompt_id`, `character`, `setting`, `challenge`, `outcome`, `teaching`; gợi ý độ dài medium được formatter thêm đồng nhất.

Tập này không tái dùng `lienntp/data/test_prompts.jsonl`, vì 25 đề của E4 đã được dùng trong chọn Base + Repair. Kiểm tra chuỗi chính xác không tìm thấy field nào trùng nguyên văn trong benchmark E4 và train/val artifact hiện có của E1/E5. Kiểm tra đó không phát hiện paraphrase và không chứng minh đề chưa xuất hiện trong pretraining. Tập đề cũng chưa có vòng review độc lập của hai thành viên; đây là giới hạn của lượt chạy này.

4.4 Quy trình sinh

Mỗi phương án nhận đúng cùng 25 đề và một seed cho mỗi đề:

Tham số	Giá trị
seed	`5410 + chỉ_số_prompt`
temperature	0,7
top-p	0,9
repetition penalty	1,1
max new tokens	400
số mẫu	1
prompt độ dài	medium, khoảng 200–260 từ

Không đầu ra nào được chọn lại sau khi đọc. E1 có hai lần dừng gần như ngay lập tức: GJ21 rỗng và GJ23 chỉ sinh `)`. Hai vị trí vẫn nằm trong 125 đầu vào chấm; phần truyện có nội dung của E1 vì vậy là 23/25. Bốn phương án còn lại sinh văn bản ở 25/25 vị trí.

“Cùng đề” nghĩa là mô hình chấm dùng cùng yêu cầu sáu trường. Bộ định dạng chuyển yêu cầu sang giao diện mà mô hình thực sự hỗ trợ: E1, E3, E4 và E5 nhận prompt năm trường; E2 chỉ

nhận character và teaching vì đó là hợp đồng train của V16. Lượt E2 dùng yêu cầu dạng ngôn ngữ tự nhiên, sai định dạng, được giữ trong `generations/e1.invalid_prompt.jsonl` nhưng không tham gia bảng cuối.

Thời gian dưới đây là độ trễ sinh trung bình theo từng dòng JSON, không gồm thời gian nạp model. Thời gian tường từ khi tạo đến khi hoàn tất file lần lượt xấp xỉ 11 giây (E2), 8 giây (E1), 173 giây (E4), 181 giây (E3) và 144 giây (E5). E4 chậm vì có thể gọi thêm một lượt rewrite; E3 chậm dù nhỏ vì chạy token-by-token qua Transformers/MPS.

4.5 Làm mù và hàm chấm điểm

125 cặp được xáo bằng seed `20260726`, đổi thành `B001`–`B125`. Yêu cầu gửi cho mô hình chấm chỉ chứa đề và truyện; không chứa candidate ID, tên thành viên, backend, latency hay cờ repair. Ánh xạ nằm riêng trong `blind_map.private.json`.

Mô hình chấm chính là `gemma-4-26b-a4b-it` qua Google GenAI, temperature 0, seed `20260726`, thinking `MINIMAL`. Đây là lượt chấm mới, tách khỏi judge local dù cùng họ Gemma đã từng được dùng ở E2. JSON schema chỉ nhận bốn số nguyên 1–10:

Trục lưu trong file	Ý nghĩa
`grammar`	ngữ pháp, mạch lạc, văn phong phù hợp trẻ em
`creativity`	độ mới và sức sống của truyện
`moral_clarity`	moral rõ và được diễn biến chứng minh
`prompt_adherence`	bám character, setting, challenge, outcome, teaching và dòng Moral

Một lượt chạy thử ban đầu yêu cầu lý do dài cho từng trục đã làm Gemma lặp hoặc cắt ngắn JSON. 15 kết quả thử được giữ trong `judge_results.blinded.jsonl` để audit nhưng **không tham gia bảng cuối**. Sau khi rút schema còn bốn điểm số, lượt chính được chạy lại từ đầu cho toàn bộ 125 đầu vào. Lượt compact đầu mất khoảng 5 phút 58 giây theo thời gian tường. Một lượt chấm khác dùng E2 sai định dạng được giữ tại `judge_scores.pre_e1_formatter_fix.jsonl` và cũng bị loại. Lượt chính cuối chạy lại đủ 125 đầu vào, lưu ở `judge_scores.blinded.jsonl`, trong khoảng 4 phút 19 giây. Có các cửa sổ chờ quota 16.000 input token/phút; độ trễ API trung bình 1,66 giây/truyện, không tính thời gian chờ quota.

4.6 Kết quả định lượng

Baseline v1 — đủ 125 lượt chấm

Điểm tổng của một truyện là trung bình bốn trục; điểm của phương án là trung bình 25 truyện, kể cả hai output gần-rỗng của E1. Vì schema judge có miền 1–10, hai output này nhận điểm 1 do Gemma chấm, không bị thay thủ công thành 0.

Phương án	Có nội dung	Ngôn ngữ	Sáng tạo	Moral	Bám đề	Overall	95% CI	Từ/truyện	Latency
E4 · Base + Repair	25/25	10,00	7,40	9,40	10,00	**9,20**	[9,08; 9,30]	257,9	5,86 s
E5 · Llama 3.2 3B fable Q4	25/25	9,88	7,04	8,56	8,28	**8,44**	[8,04; 8,80]	240,5	6,02 s
E1 · SLM 60M	23/25	5,48	3,40	2,88	1,44	**3,30**	[2,94; 3,64]	233,5	0,34 s
E2 · V16 conditioned	25/25	5,92	3,20	2,52	1,08	**3,18**	[2,80; 3,55]	275,2	0,44 s

Phương án	Có nội dung	Ngôn ngữ	Sáng tạo	Moral	Bám đề	Overall	95% CI	Từ/truyện	Latency
E3 · SmolLM2 135M + LoRA C	25/25	4,64	3,20	1,96	1,44	**2,81**	[2,61; 3,01]	305,0	7,67 s

Khoảng tin cậy trên là bootstrap 10.000 lần theo 25 đề. So sánh bắt cặp dùng điểm tổng trên cùng đề:

Cặp	Chênh lệch trung bình	CI 95%	Cao hơn/Bằng/Thấp hơn
E4 – E5	+0,76	[0,39; 1,17]	16/6/3
E4 – E1	+5,90	[5,56; 6,25]	25/0/0
E4 – E2	+6,02	[5,62; 6,42]	25/0/0
E4 – E3	+6,39	[6,16; 6,61]	25/0/0
E5 – E1	+5,14	[4,57; 5,71]	25/0/0
E5 – E2	+5,26	[4,68; 5,84]	25/0/0
E5 – E3	+5,63	[5,18; 6,06]	25/0/0
E1 – E2	+0,12	[-0,39; 0,62]	12/4/9
E1 – E3	+0,49	[0,09; 0,88]	17/4/4
E2 – E3	+0,37	[-0,05; 0,79]	13/3/9

Các CI mô tả biến thiên theo tập 25 prompt và không điều chỉnh cho 10 phép so sánh. Dù CI của E4 – E5 không chứa 0, không nên chuyển nó thành tuyên bố phổ quát: chỉ có một judge, một seed sinh và một lượt chấm.

Kiểm tra v2 — hai runner đã sửa

Nhóm đã sinh lại đủ 25 đầu ra cho cả năm hệ. Do quota Google giới hạn lượt chấm tại thời điểm cập nhật, lượt v2 được ưu tiên cho E1 và E3; hai hệ này đã có đủ 25/25 điểm. Judge v2 giữ bốn trục như baseline nhưng không yêu cầu, thưởng hay phạt dòng `Moral:` nguyên văn.

Phương án	Có nội dung	Ngôn ngữ	Sáng tạo	Moral	Bám đề	Overall	95% CI	Từ/truyện	Latency
E1 · SLM 60M · v2	25/25	8,48	4,24	4,04	1,64	**4,60**	[4,38; 4,83]	258,2	0,33 s
E3 · SmolLM2 135M + LoRA C · v2	25/25	4,76	3,48	2,24	2,04	**3,13**	[2,95; 3,31]	315,0	8,58 s

Ba hệ còn lại đã hoàn tất sinh v2 nhưng chưa đủ lượt judge v2 do quota Google, nên không được đưa vào bảng này. Vì prompt và rubric đã thay đổi, không đọc hai hàng v2 như một bảng xếp hạng chung với ba hàng baseline v1; bảng v1 phía trên là mốc đầy đủ để đối chiếu.

4.7 Phân tích trường hợp GJ20

GJ20 yêu cầu *a careful tortoise*, *a hillside orchard*, đường xe sụp, thử đường mới từng bước, và moral “Careful courage makes room for useful change.”

- E2 kể mạch lạc về rùa cứu hang cạnh thác nước sau cơn bão nhưng không thể thấy ba slot bị codec bỏ, và đổi moral thành “*a little bit of courage opens new paths*”; Gemma chấm 3,50.
- E1 viết được một truyện ngữ pháp tương đối ổn về rùa làm đổ giỏ táo, nhưng bỏ sự kiện đường sụp, đường mới và dòng `Moral:`; điểm 4,00.

- E4 kể đúng toàn bộ chuỗi đường sụp → thử đường nhỏ từng bước → đưa xe tới chợ, rồi hậu xử lý dòng cuối thành đúng moral; điểm 9,25.
- E3 bắt đầu đúng vườn cây nhưng chuyển sang xe rơi xuống ao, cú khôn ngoan và kho báu, rồi bị cụt ở "*When we*"; điểm 3,00.
- E5 kể đúng cùng chuỗi sự kiện và tự kết bằng "*Moral: Careful courage makes room for useful change.*"; điểm 9,00.

Trường hợp GJ20 minh họa nguồn chênh lệch của `prompt_adherence`. E1 và E3 tạo văn bản đúng ngữ pháp nhưng thay thế điều kiện bằng mô-típ quen thuộc; E4 và E5 giữ được chuỗi sự kiện được yêu cầu. Toàn văn của năm đầu ra được lưu trong `generations/e*.jsonl`.

4.8 Phân tích kết quả

E4 là một hệ thống suy luận nhiều bước, không phải checkpoint fine-tune độc lập. So với E5, E4 sử dụng cùng quy mô nền 3B nhưng bổ sung validator, viết lại có điều kiện và chuẩn hóa bài học. Vì vậy chênh lệch +0,76 phản ánh cả năng lực mô hình và chi phí hệ thống. E5 là mô hình sinh trực tiếp có kết quả cao nhất.

E1 có thời gian sinh thấp nhất nhưng không giữ đủ năm điều kiện; hai trường hợp dừng sớm làm giảm thêm độ tin cậy. E2 chỉ được huấn luyện với character + moral nên điểm tuân thủ năm trường gần sàn; CI của E1–E2 chứa 0. E3 sinh đủ độ dài nhưng adapter C không duy trì được điều kiện trong giao thức này; CI của E2–E3 cũng chứa 0. Các metric nội bộ như fluency, diversity, PPL hoặc vị trí LoRA do đó không thay thế phép đo tuân thủ điều kiện trên giao diện thống nhất.

Mô hình chấm không sinh phần giải thích trong lượt chính; chưa có kiểm tra thủ công bắt cặp hoặc kiểm tra ổn định qua nhiều judge/seed. Ngoài ra, E4 gọi mô hình lần thứ hai ở 5/25 đề khi validator yêu cầu rewrite, trong khi bốn hệ thống đại diện còn lại chỉ gọi một lần. Kết quả phù hợp để chọn hệ thống triển khai hiện tại nhưng chưa cô lập ảnh hưởng của trọng số, kích thước mô hình và chi phí suy luận.

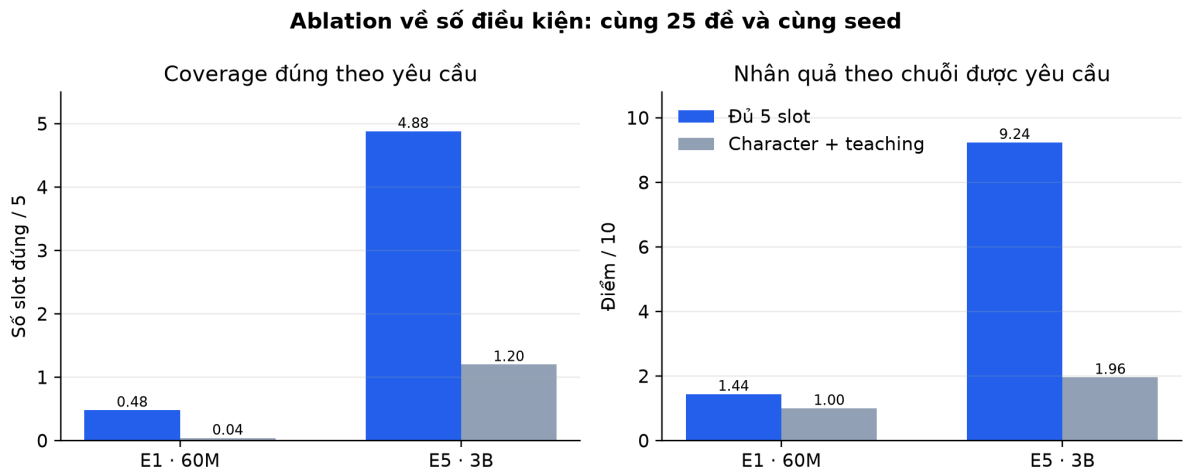
4.9 Thí nghiệm phân tích không huấn luyện lại

Ba thí nghiệm bổ sung tách các thành phần thường bị gộp trong điểm tuân thủ:

1. độ sẵn có của điều kiện đầu vào;
2. khả năng dùng điều kiện để thay đổi chuỗi sự kiện;
3. đóng góp riêng của bước repair trong E4.

E1 và E5 được sinh lại trên cùng 25 đề, cùng seed và decoding, một lần với đủ năm trường và một lần chỉ có `character + teaching`. Lượt đủ năm trường tái dùng đầu ra global đã khóa; lượt hai trường là 50 đầu ra mới. Mô hình chấm riêng năm biến coverage dạng boolean, dòng `Moral:`, trait→choice, choice→outcome, độ nhất quán nội tại và độ nhất quán với chuỗi được yêu cầu.

Model	Điều kiện đưa vào	Coverage /5	Ba slot setting/challenge/outcome /3	Nhân quả theo yêu cầu /10
E1 · 60M	đủ năm slot	0,48	0,32	1,44
E1 · 60M	character + teaching	0,04	0,04	1,00
E5 · 3B	đủ năm slot	**4,88**	**2,96**	**9,24**
E5 · 3B	character + teaching	1,20	0,16	1,96



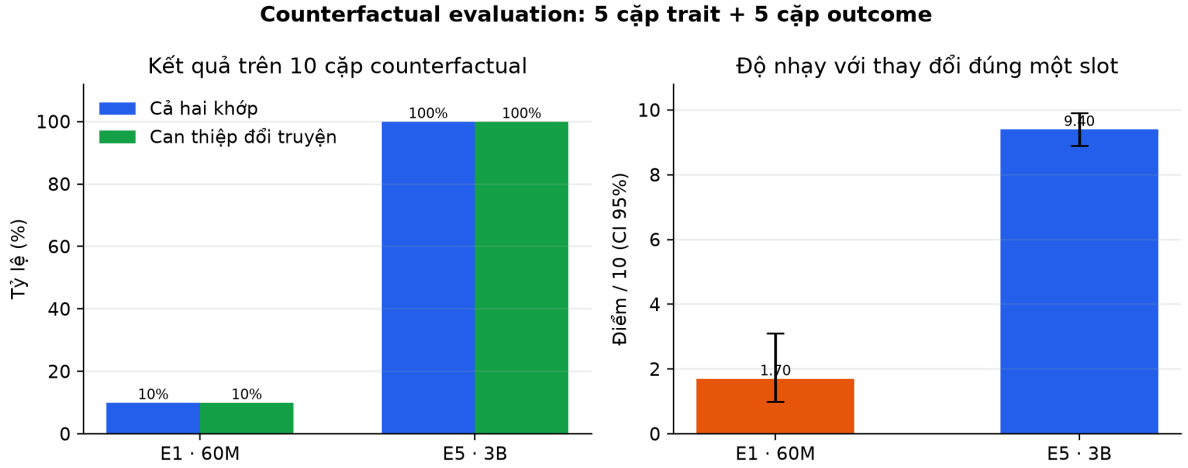
Hình 26: Coverage và nhân quả theo yêu cầu khi đưa vào hai hoặc năm điều kiện.

Ở E1, bổ sung ba trường tăng coverage +0,44/5 với CI bootstrap bắt cặp [0,04; 0,92], nhưng cả hai điều kiện vẫn gần mức sàn. Độ nhất quán nhân quả nội tại không khác rõ (4,76 so với 5,08; chênh −0,32, CI chứa 0), nghĩa là tính nhất quán nội tại không bảo đảm tuân thủ chuỗi sự kiện được yêu cầu.

Ở E5, đủ năm slot làm coverage tăng +3,68/5 [3,20; 4,08] và nhân quả theo yêu cầu tăng +7,28/10 [6,60; 7,92]. Kết quả "E2 hai điều kiện gần E1 năm điều kiện" do đó không chứng minh hai giao diện tương đương; cả hai SLM nhỏ đều có điểm tuân thủ gần sàn. Khi mô hình sử dụng được prompt có cấu trúc, ba trường bổ sung làm thay đổi đáng kể đầu ra.

Đánh giá phản thực (counterfactual). Mỗi cặp giữ nguyên setting, challenge, các trường còn lại và seed; chỉ thay một điều kiện để kiểm tra đầu ra có đổi đúng hướng hay không. Mười cặp gồm năm cặp thay trait và năm cặp thay outcome. Mô hình chấm liệu mỗi truyện có khớp biến thể tương ứng và thay đổi điều kiện có thực sự làm đổi lựa chọn hoặc cách giải quyết hay không.

Model	Cả hai truyện khớp biến thể	Can thiệp đổi truyện	Counterfactual sensitivity /10
E1 · 60M	10%	10%	1,70 [1,00; 3,10]
E5 · 3B	**100%**	**100%**	**9,40 [8,90; 9,90]**

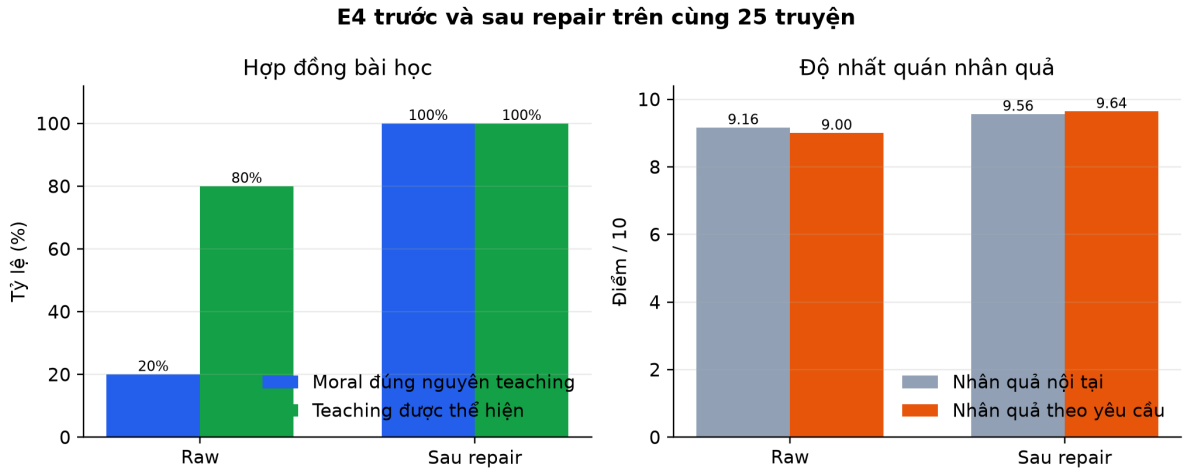


Hình 27: Counterfactual sensitivity của E1 và E5 trên mười cặp chỉ thay một điều kiện.

E1 đạt 2,40/10 ở thay đổi trait và 1,00/10 ở thay đổi outcome; E5 đạt 8,80 và 10,00. Chênh lệch độ nhạy E5–E1 là +7,70 [6,20; 8,70]. Trong giao thức này, E5 phản ứng với thay đổi điều kiện ở cấp diễn biến thay vì chỉ tái tạo từ khóa. Kết quả không chứng minh năng lực suy luận nhân quả ngoài miền vì chỉ có 10 cặp, một seed, một Gemma judge và không có can thiệp lên biểu diễn ẩn.

E4 trước và sau repair. Cùng 25 truyện được làm mù và chấm độc lập ở bản thô và bản cuối. Có 21/25 lượt thực hiện ít nhất một hành động, gồm 5 rewrite và 19 chuẩn hóa moral (các nhóm chồng nhau).

Chỉ số	Raw	Sau repair	Chênh bắt cặp
Đúng nguyên teaching ở dòng `Moral:` cuối	20%	**100%**	+80 điểm % [64; 96]
Teaching được thể hiện	80%	**100%**	+20 điểm % [4; 36]
Nhân quả nội tại /10	9,16	**9,56**	+0,40 [0,20; 0,60]
Nhân quả theo yêu cầu /10	9,00	**9,64**	+0,64 [0,40; 0,92]
Trait→choice / choice→outcome	92% / 100%	92% / 100%	0 / 0



Hình 28: Đóng góp của repair đối với hợp đồng moral và độ nhất quán nhân quả.

Repair chủ yếu bảo đảm định dạng đầu ra và tính đúng của bài học. Tỷ lệ trait→choice→outcome đã cao ở truyện thô và không thay đổi sau repair; do đó năng lực này không được quy cho hậu xử lý.

5. Thảo luận

5.1 Tổng hợp các phát hiện

Loss, perplexity và điểm nội bộ của E1–E3 đều cải thiện sau tối ưu, nhưng mức tuân thủ trên giao thức chung vẫn thấp. Do đó, độ phù hợp phân bố token và chất lượng ngôn ngữ không phải đại diện thay thế cho khả năng điều kiện hóa có cấu trúc. Sai khác giữa giao diện train và giao diện đánh giá ở E1/E3 càng cho thấy hợp đồng prompt phải được giữ cố định khi đo năng lực này.

Thí nghiệm hai so với năm điều kiện phân biệt **điều kiện có mặt** với **điều kiện được sử dụng**. E1 tạo truyện có mức nhất quán nội tại tương tự ở hai giao diện nhưng gần như không bám chuỗi sự kiện được yêu cầu. Ngược lại, độ phủ và độ nhất quán nhân quả của E5 tăng đồng thời khi cung cấp đủ năm trường. Vì vậy, một truyện tự nhất quán vẫn có thể không phụ thuộc vào prompt.

Đánh giá phản thực cung cấp bằng chứng mạnh hơn việc kiểm tra từ khóa: khi chỉ thay trait hoặc outcome, E5 thay đổi lựa chọn hoặc đường giải quyết tương ứng trong 10/10 cặp, trong khi E1 chỉ đạt 1/10. Kết quả này xác nhận độ nhạy có hướng đối với điều kiện trong tập kiểm thử, nhưng chưa chứng minh suy luận nhân quả ngoài miền.

Repair của E4 tác động lên một thành phần khác. Nó chuẩn hóa bài học và cải thiện nhẹ điểm nhất quán, trong khi hai liên kết trait→choice và choice→outcome đã có trong bản thô và không đổi sau repair. Vì vậy cần báo cáo riêng năng lực sinh của checkpoint, độ tin cậy của quy trình và chi phí gọi mô hình bổ sung.

5.2 Hàm ý cho việc lựa chọn hệ thống

Trong giao thức hiện tại, E4 đạt điểm trung bình cao nhất (9,20), còn E5 là mô hình sinh trực tiếp tốt nhất (8,44). Chênh lệch E4–E5 là +0,76 với CI bootstrap bắt cặp [0,39; 1,17]. E4 phù hợp khi mục tiêu là độ tin cậy đầu ra và chấp nhận chi phí validator/repair; E5 phù hợp khi cần một mô hình đơn, không có lượt repair bổ sung.

Lựa chọn giữa hai hệ thống phụ thuộc vào mục tiêu triển khai, không chỉ điểm trung bình: E4 có độ tuân thủ cao hơn nhưng latency và số lần gọi mô hình lớn hơn; E5 đơn giản hơn và giữ chất lượng cao mà không cần repair.

5.3 Các yếu tố đe dọa tính hợp lệ

Tính hợp lệ nội tại. E4 được phép gọi mô hình lần thứ hai ở 5/25 đề; do đó phép so sánh không giữ cố định chi phí suy luận. Năm hệ thống đại diện cũng khác về tokenizer, kích thước và dữ liệu tiền huấn luyện, nên kết quả không cô lập hiệu ứng của một biến duy nhất.

Tính hợp lệ của phép đo. Điểm chính đến từ một Gemma judge không sinh phần giải thích. Chưa có đánh giá thủ công bắt cặp, kiểm tra độ nhất quán liên giám khảo hoặc hiệu chỉnh thang điểm bằng mẫu do người chấm.

Tính hợp lệ bên ngoài. Tập đánh giá gồm 25 đề cùng miền truyện ngụ ngôn tiếng Anh, một seed sinh và một cấu hình giải mã. Kết luận không được mở rộng sang thể loại khác, ngôn ngữ khác hoặc năng lực suy luận nhân quả tổng quát.

Tính tái lập. E4 và E3 thiếu trainer state, đường loss/LR và thời gian huấn luyện; E5 thiếu eval cuối epoch 3. Những khoảng trống này không ảnh hưởng việc chạy artifact cuối nhưng hạn chế khả năng tái lập đầy đủ quá trình huấn luyện.

6. Kết luận

Kết quả chính của nghiên cứu là sự phân tách ba mức thường bị gộp thành "bám điều kiện": nhắc lại trường đầu vào, duy trì chuỗi sự kiện phù hợp và thay đổi diễn biến khi điều kiện bị can thiệp. Điểm ngôn ngữ và nhất quán nội tại chủ yếu phản ánh chất lượng bề mặt hoặc tính hợp lý tự thân; chúng không cho biết điều kiện có chi phối diễn biến hay không. E5 đạt đồng thời độ phủ cao, độ nhất quán nhân quả cao và độ nhạy phản thực 9,40/10, tạo bằng chứng rằng điều kiện được sử dụng để chi phối diễn biến trong tập kiểm thử. E1 không đạt kết quả tương ứng dù truyện vẫn có thể tự nhất quán.

Kết quả E4 xác lập ranh giới giữa năng lực mô hình và độ tin cậy hệ thống. Repair đưa bài học về đúng hợp đồng và cải thiện điểm cuối, nhưng không tạo thêm liên kết trait→choice hoặc choice→outcome. Do đó, hệ thống sinh có điều kiện nên báo cáo riêng chất lượng bản thô, hiệu ứng repair và chi phí suy luận, thay vì quy toàn bộ điểm cuối cho checkpoint.

Các kết luận trên giới hạn ở 25 đề, một seed và một LLM giám khảo. Đánh giá tiếp theo cần mở rộng tập phản thực, dùng nhiều seed, bổ sung chấm mù của con người và kiểm tra liên giám khảo; trọng tâm là xác nhận độ nhạy có hướng đối với điều kiện, không phải tìm một ngưỡng tham số phổ quát.

7. Khả năng tái lập và đóng góp của các thành viên

7.1 Phân công thực hiện thí nghiệm

Mã sinh viên	Họ và tên	Đóng góp chính
20252611M	Lê Hải Triều	E1: tiền huấn luyện Llama 30M/60M, can thiệp dữ liệu và đánh giá hậu huấn luyện
20252612M	Đào Đức Tùng	E2: GPT 63M huấn luyện từ đầu, tokenizer và điều kiện hóa nhân quả
20252610M	Nguyễn Công Thanh	E3: bóc tách vị trí LoRA trên SmolLM2-135M
20252130M	Nguyễn Thị Phương Liên	E4: SFT/LoRA, validation, hậu xử lý và repair
20252737M	Nguyễn Đình Lê Hoàng	E5: QLoRA Llama 3.2 3B, lượng tử hóa và triển khai

Nhóm cùng thực hiện giao thức đánh giá thống nhất, các thí nghiệm loại trừ và tổng hợp kết quả. Nhãn E1–E5 được dùng để phân biệt năm hướng tiếp cận độc lập và hệ thống đại diện của chúng, không biểu thị thứ tự thực hiện, mức điều kiện thực nghiệm hay xếp hạng đóng góp cá nhân.

7.2 Tệp mô hình và khả năng tái lập

Hướng	Cấu hình/log chính	Đầu ra/mẫu	Khoảng trống
E1 · Lê Hải Triều (20252611M)	log repo + Drive `Trieulh/{loss_log_*,ckpt_*/*/trainer_state.json}`	analysis, 19 figure artifact, checkpoint/GGUF	tổng wall-clock 60M qua bốn phiên không được ghi đầy đủ
E2 · Đào Đức Tùng (20252612M)	`feat/td:runs/v16/run.json`; Drive `TD/E1-V16/{training-states,repo-evidence}` (tên thư mục artifact cũ)	fixed-screen JSON, 25 generation global, ba model runnable	conditioning trace dừng ở 800; causal chỉ có endpoint
E3 · Nguyễn Công Thanh (20252610M)	báo cáo repo; Drive `ThanhNC/{merged,gguf}`	base/best HF + GGUF, cấu hình Ollama	vẫn thiếu log loss/LR, thời gian và raw generation local
E4 · Nguyễn Thị Phương Liên (20252130M)	manifest/báo cáo repo; Drive `LienNTP/Models.docx` → `model.zip`	bốn GGUF + Modelfile; CSV đánh giá local/global	archive 7,95 GB không chứa trainer state, loss/LR hay thời gian
E5 · Nguyễn Đình Lê Hoàng (20252737M)	notebook; Drive `Hoangndl/models/1000/outputs/checkpoint-339/trainer_state.json`	adapter, GGUF 1/3 epoch + 25 generation global	eval epoch 3 vẫn thiếu trong trainer state; run 1 epoch không có state
Vòng chung	`scripts/global_benchmark.py`; `results/global_judge/global_prompts_v1.jsonl`	125 generation, 125 Gemma score, `summary.json`	chưa có human audit/judge thứ hai
Ablation	`scripts/ablation_benchmark.py`; `results/ablation_judge/protocol.json`	90 generation mới, 190 score từng truyện, 20 score cặp	10 cặp counterfactual, một seed và một Gemma judge
Hình theo track	`scripts/plot_track_artifacts.py`	E2 loss/LR + screen; E3 ablation; E4 human eval; E5 loss/LR; E4 automatic dùng SVG gốc	E3/E4 không có trainer state nên không có loss curve thực

Ứng dụng chung đọc mô hình từ `config/models.json`. Bộ chạy chung nạp mô hình trực tiếp để loại phụ thuộc vào trạng thái Ollama cục bộ. `summary.json` lưu model digest, cấu hình sinh, mô hình chấm, seed làm mù và thống kê; năm tệp generation JSONL cùng

`judge_scores.blinded.jsonl` là nguồn thẩm quyền của bảng xếp hạng trên. `run_manifest.json` lưu phiên bản của đề, đầu ra, kết quả chấm và bộ chạy.

Tài liệu tham khảo

1. Nadas, M. và cộng sự. *TF1-EN-3M: Three Million Synthetic Moral Fables for Training Small, Open Language Models*, 2025. Bộ dữ liệu.
2. Kaplan, J. và cộng sự. *Scaling Laws for Neural Language Models*, 2020.
3. Hoffmann, J. và cộng sự. *Training Compute-Optimal Large Language Models*, 2022.
4. Hu, E. J. và cộng sự. *LoRA: Low-Rank Adaptation of Large Language Models*, 2021.
5. Rafailov, R. và cộng sự. *Direct Preference Optimization: Your Language Model is Secretly a Reward Model*, 2023.
6. Dong, H. và cộng sự. *RAFT: Reward rAnked FineTuning for Generative Foundation Model Alignment*, 2023.
7. Hinton, G., Vinyals, O., Dean, J. *Distilling the Knowledge in a Neural Network*, 2015.