

Huấn luyện từ đầu một Small Language Model 30M tham số cho truyện ngụ ngôn thiếu nhi tiếng Anh

Timeline huấn luyện, các phương pháp cải thiện và giới hạn đo được của mô hình siêu nhỏ

trieulh - IT5410

2026-07-24

Contents

Tóm tắt	2
1. Bài toán và thiết lập	2
2. Timeline huấn luyện và đánh giá	2
3. Các phương pháp cải thiện sau huấn luyện	6
4. Kết luận	9
5. Tái lập	10
Tài liệu tham khảo	10

Tóm tắt

Đồ án huấn luyện từ đầu một mô hình ngôn ngữ kiểu Llama 30M tham số trên kho truyện ngụ ngôn TF1-EN-3M, và trả lời câu hỏi: trên một tác vụ được giới hạn tốt, mô hình nhỏ tiến gần được đến đâu so với một LLM lớn hơn 130 lần (Qwen3-4B). Quá trình gồm ba giai đoạn huấn luyện theo timeline (baseline chẩn đoán, cấp đủ ngân sách token theo scaling law, can thiệp dữ liệu) đưa điểm LLM-judge từ 2.5 lên 7.0/10, tiếp theo là năm phương pháp post-training được kiểm chứng dưới cùng một protocol (DPO, SFT-on-best, RAFT, GRPO-lite, distillation): bốn phương pháp null, một phương pháp làm mô hình xấu đi; trong khi tìm kiếm best-of-N tại thời điểm suy luận thu được +0.8 điểm đã kiểm chứng (7.7 thành 8.55, sát mốc 9.75 của Qwen-4B) và được triển khai vào ứng dụng. Nghiên cứu cũng tự đo nhiễu của LLM-judge (+0.4 điểm ở $n=15$) và dùng nó để rút lại hai kết luận dương tính giả. Kết luận trung tâm: dư địa chất lượng của mô hình nhỏ tồn tại ở mức từng mẫu sinh nhưng không huấn luyện được vào phân bố mặc định bằng phương pháp chi phí thấp; nâng sản chất lượng đòi hỏi pretraining tốt hơn. Mô hình cuối sinh truyện trọn vẹn ở ~949 token/giây, nhanh hơn mốc 4B khoảng 50 lần.

1. Bài toán và thiết lập

Câu hỏi nghiên cứu. Trên tác vụ sinh truyện ngụ ngôn thiếu nhi có điều kiện theo 5 slot tường thuật (Main character, Setting, Challenge, Outcome, Teaching), một SLM 30M huấn luyện từ đầu đạt bao nhiêu phần chất lượng của Qwen3-4B, và đổi lại hiệu năng gì?

Cơ sở lý thuyết. Mô hình autoregressive được huấn luyện bằng MLE trên chain rule (Week 6); ngân sách token đặt theo scaling law (Kaplan 2020) và mốc Chinchilla ~20 token/tham số (Hoffmann 2022), cho phép lập dữ liệu tới 4 epoch (Muennighoff 2023). Các phương pháp cải thiện lần lượt dựa trên DPO (Rafailov 2023), RAFT (Dong 2023), REINFORCE với baseline (Williams 1992; Week 10) dạng GRPO (Shao 2024), và distillation (Hinton 2015).

Dữ liệu. klusai/ds-tf1-en-3m: mỗi bản ghi gồm prompt 5 slot và một truyện. Mẫu huấn luyện có dạng <5 slot + gợi ý độ dài> <|story|> <truyện> <|end|>; chỉ phần truyện đóng góp vào loss (conditioning được mask). Lọc giữ truyện 60-320 từ; mỗi slot bị che ngẫu nhiên (slot dropout) để mô hình quen với mọi tập con slot; tokenizer BPE riêng 12k vocab giữ bảng embedding nhỏ.

Kiến trúc. Decoder kiểu Llama (RoPE, GQA, RMSNorm, SwiGLU, tied embeddings):

Thành phần	Giá trị	Thành phần	Giá trị
Tham số	~36.6M	Optimizer	AdamW (0.9, 0.95), wd 0.1
Hidden / FFN	512 / 2048	Lịch LR	WSD, đỉnh 3e-3
Layer / head / KV	8 / 8 / 2 (GQA)	Batch hiệu dụng	128 chuỗi (~33k token/bước)
Vocab / seq len	12.000 / 512	Precision / grad clip	fp16 (T4) / 1.0

Trần seq 512 (trừ prompt còn ~400-460 token cho truyện) là trần cứng cho độ dài truyện, sẽ xuất hiện lại ở phần giới hạn.

2. Timeline huấn luyện và đánh giá

Giai đoạn	Dữ liệu, bước	Loss	PPL	Judge	Sự kiện chính
v1 baseline	150k, 900	~1.80	-	2.5	cố ý under-train để chẩn đoán
Phase 1	400k, 1800	1.447	4.18	6.0	cấp đủ ngân sách token
(sửa sampling)	-	-	-	6.2	repeat_penalty 1.3 về 1.1
Phase 2	400k v2, 3600	1.278	3.56	7.0	cần thiếp dữ liệu, resume từ 1800
Qwen3-4B (mốc)	-	-	-	9.75	lớn hơn 130 lần

2.1 v1: chẩn đoán under-training

Baseline chạy với ~1.7 token/tham số (so với mốc Chinchilla 20) cho điểm judge 2.5: truyện rời rạc, lặp và bỏ prompt. Chẩn đoán theo scaling law: mô hình không thiếu capacity mà thiếu dữ liệu; đây là giả thuyết kiểm chứng được và rẻ hơn nhiều so với đổi kiến trúc.

2.2 Phase 1: cấp đủ ngân sách token

Tăng lên 400k truyện unique, 1800 bước (~600M token qua 4 epoch). Loss giảm từ 7 về 1.447, judge tăng 2.5 lên 6.0, xác nhận giả thuyết under-training. Một chỉnh nhỏ ở sampling (repeat_penalty 1.3 xuống 1.1, vì mức phạt cao trừng phạt cả tên nhân vật khiến nhân vật bị đổi giữa truyện) thêm +0.2 điểm.



Figure 1: Loss huấn luyện toàn trình, Phase 2 resume tại bước 1800.

Đọc biểu đồ. Trục hoành là bước huấn luyện, trục tung là cross-entropy loss: trung bình âm log-likelihood mỗi token, đo mức “bất ngờ” của mô hình trước token thật; thấp hơn nghĩa là dự đoán tốt hơn. Đường loss đi theo lịch Warmup-Stable-Decay (WSD): warmup (LR tăng dần, tránh sốc gradient khi trọng số còn ngẫu nhiên), stable (LR đỉnh 3e-3, giai đoạn học chính), decay (LR giảm về 0, mô

hình “kết tinh” kiến thức nên loss rơi thêm một nấc rõ ở cuối mỗi phase). Đường cong mượt, không có spike: công thức huấn luyện ổn định.




Figure 2: Kiểm tra scaling law trên trục log-log.

Độc biểu đồ. Cả hai trục lấy logarit; nếu loss tuân quan hệ lũy thừa $\text{loss} \sim \text{bước}^{(-k)}$ thì các điểm nằm trên một đường thẳng. $R^2 = 0.96$ nghĩa là đường thẳng giải thích 96% biến thiên: lần chạy nằm đúng chế độ power-law mà Kaplan (2020) dự đoán và **chưa plateau**, tức thêm token vẫn còn lợi. Đây là bằng chứng định lượng cho hướng scale tiếp ở phần kết luận.

2.3 Phase 2: can thiệp dữ liệu có chủ đích

Rà soát định tính Phase 1 phát hiện **template collapse**: cụm “wise old owl” có trong 28% truyện thật nhưng chiếm ~90% truyện sinh ra, vì sampling khuếch đại mode mạnh nhất của phân bố. Can thiệp trên corpus v2: giới hạn truyện chứa cụm này ở 10%, đồng thời giảm slot dropout của Teaching/Outcome (0.30 về 0.15) để mô hình thấy moral trong conditioning thường xuyên hơn và học bám theo nó. Resume từ bước 1800 chạy tiếp đến 3600.




Figure 3: Tần suất template trước và sau can thiệp.

Độc biểu đồ. Cột là tỉ lệ truyện sinh ra có chứa cụm “wise old owl”. Sau can thiệp, tỉ lệ giảm từ 90% xuống 23%, thấp hơn cả prior 28% của dữ liệu thật: sửa tại nguồn dữ liệu hiệu quả hơn sửa ở khâu sampling, và cùng công thức áp dụng được cho các khuôn mẫu khác (happy ending, motif lặp).




Figure 4: Perplexity held-out của hai phase.

Độc biểu đồ. Perplexity (PPL) = e^{loss} trên tập held-out, diễn giải trực quan là “số lựa chọn token tương đương” mà mô hình phân vân; thấp hơn là chắc chắn hơn. PPL 3.56 của Phase 2 chỉ cách sản lý thuyết $e^{1.278} = 3.59$ chưa đến 1%: hành vi trên dữ liệu chưa từng thấy khớp với loss huấn luyện, tức **không overfit** dù mô hình nhỏ, nhờ kho dữ liệu unique đủ lớn.




Figure 5: Metric nội tại của truyện sinh so với truyện thật.

Độc biểu đồ. Các metric không cần văn bản tham chiếu, so truyện sinh với truyện thật held-out: **Distinct-1/2** là tỉ lệ unigram/bigram khác nhau, đo đa dạng từ vựng (cao = ít lặp từ); **Self-BLEU** đo độ giống nhau giữa các truyện trong cùng một tập (thấp = không sinh rập khuôn một kiểu); **Flesch reading ease** đo độ dễ đọc (dải 80-100 phù hợp thiếu nhi). Truyện sinh khớp truyện thật trên cả ba nhóm (Distinct-2 chênh ~4%, Self-BLEU chênh 0.001, Flesch 79.9 so với 80.0): mô hình học được **hình dạng thống kê của miền dữ liệu** chứ không chỉ trôi chảy bề mặt.

Verdict tự động Phase 2: 7 PASS / 2 WARN / 0 FAIL (hai WARN: Flesch hụt 0.1 điểm so dải mục tiêu; overlap phân bố độ dài 43% do mô hình có “độ dài tự nhiên” riêng).

Độc biểu đồ. Điểm LLM-judge trung bình (thang 10) tại từng mốc của timeline; vạch tham chiếu là Qwen3-4B (9.75). Bước nhảy lớn nhất (2.5 lên 6.0) đến từ ngân sách token, bước tiếp theo (6.2 lên




Figure 6: Tiến trình điểm judge qua các giai đoạn.

7.0) từ can thiệp dữ liệu. Bài học xuyên suốt: **ở quy mô nhỏ, dữ liệu và token quyết định, kiến trúc là thứ yếu.**

3. Các phương pháp cải thiện sau huấn luyện

Sau Phase 2, hạn chế lớn nhất còn lại là prompt-adherence (~70%, và đã đo được rằng nhiệt độ sampling không thay đổi nó) cùng độ ổn định chất lượng giữa các lần sinh. Năm phương pháp được thử lần lượt, tất cả đánh giá dưới **một protocol cố định**: sinh với seed bất cập trên prompt held-out, LLM-judge chấm 4 trục (grammar, creativity, moral, adherence), so với baseline Phase 2.

3.1 DPO trên 194 cặp preference: null

Sinh 2 truyện mỗi prompt từ Phase 2, judge chấm, giữ cặp có margin ≥ 1.0 làm (chosen, rejected), huấn luyện DPO cục bộ. Tín hiệu trong lúc train hoàn hảo (reward accuracy đạt 1.0, perplexity không drift) và một phép thăm dò ban đầu còn gợi ý adherence tăng 5 điểm. Nhưng dưới protocol chuẩn: **7.88 so với 8.02 của baseline, null**; phép thăm dò +5 điểm về sau được chứng minh nằm trong nhiễu judge (Mục 3.4). Cơ chế: chosen và rejected đều rút từ cùng một mô hình với chất lượng sản phẩm, tín hiệu preference tương đối quá yếu để dịch phân bố mặc định.

3.2 Thăm dò dư địa bằng best-of-N: +0.8 điểm, được triển khai

Câu hỏi phân định: mô hình **không thể** viết hay, hay chỉ **không ổn định**? Sinh K=3 ứng viên mỗi prompt (nhiệt độ 0.5/0.8/1.1), judge chọn bản tốt nhất: trung bình một mẫu 7.72 tăng lên **8.55**, nhiều mẫu đơn lẻ đạt 9.0-9.5 (mốc 4B: 9.75). Kết luận: ràng buộc là **phương sai, không phải capacity**; mô hình đã chứa sẵn truyện gần chất lượng tham chiếu. Best-of-N (tắt/3/5) được đưa vào ứng dụng: backend sinh N bản, judge chấm, trả về bản tốt nhất kèm log điểm từng ứng viên. Phát hiện này định nghĩa lại mục tiêu các thí nghiệm sau: không phải dạy mô hình điều mới, mà dồn xác suất về các mode tốt sẵn có.

3.3 RAFT, SFT lọc ngưỡng tuyệt đối: null

Nếu best-of-N tìm ra mẫu tốt, huấn luyện trên chúng có nội hóa được mức tăng? Corpus 200 truyện **đều đạt judge ≥ 9.0** (trung bình 9.22; tỉ lệ prompt đạt ngưỡng chỉ 23%), fine-tune lr 2e-5, 3 epoch.

Kết quả: **7.60 so với 7.78, null**, ppl drift +0.5%. Cơ chế: mẫu tự sinh là in-distribution nên SFT chỉ tô đậm mode sẵn có; 60k token đặt cạnh prior pretraining 600M token là cú hích quá nhỏ; và gradient của SFT không có thành phần âm nào đẩy xác suất ra khỏi các mode tầm thường.

3.4 Đo nhiễu của chính judge: rút lại hai dương tính giả

Chấm lại cùng một mô hình hai lần (cùng protocol, cùng seed): RAFT cho 7.38 và 7.82, baseline 7.73 và 7.82, GRPO 8.00 và 8.45. Suy ra **nhiều judge $\sim \pm 0.4$ điểm ở $n=15$** , ngang cỡ các hiệu ứng đang cần phát hiện.




Figure 7: Chấm lặp cùng một checkpoint.

Đọc biểu đồ. Mỗi cột dọc là hai lần chấm độc lập của cùng một mô hình; độ dài đoạn nối hai điểm chính là nhiễu đo được. Điểm kim cương bên phải cho thấy độ trải co lại khi tăng cỡ mẫu lên $n=45$. Từ đây báo cáo áp dụng quy tắc: chênh lệch dưới 0.5 điểm ở $n=15$ coi là nhiễu; kết luận quan trọng phải xác nhận ở $n=45$ với seed bắt cặp. Hai kết quả từng được ghi nhận (“DPO +5 adherence”, “GRPO +0.45”) bị rút lại theo quy tắc này.

3.5 GRPO-lite, RL on-policy với baseline theo nhóm: null ở ngân sách này

Thành phần còn thiếu của các phương pháp trên là **exploration và gradient âm**: GRPO-lite (dạng REINFORCE + baseline của Week 10) sinh rollout mới mỗi bước, chuẩn hóa advantage trong nhóm cùng prompt theo $(r - \text{mean}) / \text{std}$, phạt KL so với mô hình gốc. Chạy 60 bước x 16 rollout (~960 lần gọi judge, ~5 giờ). Ở $n=15$ đọc được +0.45; mở rộng đúng quy tắc lên $n=45$: **co về +0.09 ($t=0.54$), null**. Chẩn đoán: KL cuối $\sim 1e-3$ nats/token, policy gần như chưa dịch chuyển; kết luận đúng phạm vi là “GRPO ở ngân sách này chưa đủ”, không phải “GRPO sai”. Nút chặn là giá reward (judge mất ~15 giây một lần gọi); một reward model 30M huấn luyện để thay judge đã rút công kiểm định (pairwise accuracy 46.7%, ngang ngẫu nhiên, với ~500 nhãn).

3.6 Distillation từ teacher: dịch chuyển thật, nhưng xuống

Hướng cuối có bằng chứng: 600 truyện do Qwen3-4B sinh theo đúng 5 slot (ràng buộc văn phong đơn giản, 150-250 từ), SFT 2 epoch. Đây là tín hiệu **off-distribution thật** và là phương pháp duy nhất làm mô hình dịch chuyển đo được (loss trên văn teacher 2.94 so với 0.67 trên văn tự sinh; ppl drift +4.4%), nhưng theo chiều xấu: **7.57 so với 7.94 ($n=45$, $t=-1.55$)**. Mô hình 30M bắt chước văn phong bề mặt của teacher vượt quá capacity và đánh mất độ trôi chảy bản địa, đúng failure mode “imitation học style, không học content” (Gudibande 2023).

3.7 Toàn cảnh chiến dịch




Figure 8: Năm phương pháp huấn luyện và một phương pháp suy luận, cùng một protocol.

Độc biểu đồ. Mỗi cụm hai cột là một thí nghiệm: cột xám là baseline Phase 2 đo trong cùng phiên đánh giá, cột màu là phương pháp (cột xanh lá: best-of-N); số trên cột là chênh lệch và cỡ mẫu n. Bốn phương pháp huấn luyện đều nằm trong biên nhiễu của baseline, distillation âm rõ, chỉ best-of-N vượt hẳn lên.

Phương pháp	Tín hiệu	Exploration	Gradient âm	Kết quả
DPO (194 cặp)	preference tương đối	không	ngầm	null (7.88 / 8.02)
SFT-on-best (42)	best trong batch	không	không	null (7.98 / 8.02)
RAFT (200 >= 9.0)	ngưỡng tuyệt đối	không	không	null (7.60 / 7.78)
GRPO-lite (60 bước)	advantage nhóm	có	có	null ở ngân sách này (+0.09)
Distill teacher (600)	off-distribution	của teacher	không	âm (-0.37, ppl +4.4%)
Best-of-N (suy luận)	judge chọn lọc	có (test-time)	-	+0.8, đã triển khai

3.8 Đối đầu ba mô hình trong ứng dụng: chốt mô hình cuối

Kiểm chứng cuối bằng chính API của ứng dụng: Phase 1, Phase 2 và Phase 2+DPO chạy hai use case (UC1 sinh tự do không slot; UC2 đủ 5 slot), 4 prompt mỗi ô, **cùng seed bất cập giữa ba mô hình**, hai giám khảo độc lập: judge Qwen3-4B của app và Claude (khác họ mô hình) đọc chấm tay toàn bộ 24 truyện.

Độc biểu đồ. Hai panel là hai use case; trong mỗi cụm, cột xanh là điểm judge tự động, cột cam là điểm Claude chấm tay; trục tung thang 10. Hai giám khảo khác họ đồng thuận về thứ tự xếp hạng, dù judge Qwen chấm hào phóng hơn ~1-1.5 điểm ở sinh tự do, minh họa thêm cho thiên lệch của judge đơn (Mục 3.4).




Figure 9: Đối đầu ba mô hình với seed bắt cặp, hai giám khảo.

	UC1 judge/Claude	UC2 judge/Claude	Adherence UC2	Flesch UC1
Phase 1	8.19 / 6.62	4.75 / 4.38	3.5	70.8
Phase 2	8.12 / 7.00	7.44 / 6.69	7.0	80.8
Phase 2+DPO	7.06 / 6.25	7.19 / 6.94	5.8	75.4

Ba quan sát: (1) mức tiến bộ thật là Phase 1 sang Phase 2 và chỉ hiện rõ ở sinh có điều kiện, nơi Phase 1 trượt slot nặng (một prompt bị sinh thành truyện khác hẳn); (2) với cùng seed, truyện của Phase 2 và DPO **giống hệt nhau phần lớn độ dài, chỉ rẽ nhánh vài câu cuối** (5/8 cặp): bằng chứng trực quan cho kết luận DPO không dịch phân bố; (3) hiện tượng “DPO điểm cao hơn” đôi khi thấy trên giao diện là nhiều một lần chấm của judge đơn. **Mô hình cuối: s1m-30m-p2 (Phase 2), dùng kèm best-of-N = 3 trong ứng dụng** (cấu hình 8.55/10 đã kiểm chứng); bản DPO giữ trong registry để trình diễn thí nghiệm.

4. Kết luận

4.1 Vì sao mô hình không thể tốt hơn: bốn giới hạn đo được

- Phân bố mặc định nằm ở tối ưu cục bộ do pretraining quyết định.** Dữ liệu tự sinh (in-distribution) không dịch được phân bố vì thiếu gradient âm; dữ liệu teacher (off-distribution) dịch được thì vượt capacity của học trò và làm giảm chất lượng. Hai chiều thất bại bổ sung nhau thành một kết luận: không có đường tắt post-training chi phí thấp; nâng sàn phải bằng pretraining (nhiều dữ liệu hơn, sạch hơn, mô hình lớn hơn).
- Tín hiệu phản hồi AI tự tạo quá yếu và nhiễu.** Judge có nhiễu ± 0.4 ở $n=15$ (tự đo), từng tạo hai dương tính giả; reward model học từ ~500 nhãn của nó rất cồng kềnh kiểm định. Vòng lặp tự cải thiện thiếu tín hiệu sạch để hội tụ.
- Capacity 30M chặn adherence và độ bền logic.** Adherence trần ~70-80% (hay rơi các slot trừu tượng như Challenge/Outcome), lỗi đại từ và phi logic cục bộ xuất hiện rải rác; không phương pháp alignment nào dịch được các con số này.
- Trần kiến trúc 512 token** giới hạn truyện ở ~340 từ và làm gợi ý độ dài gần như vô hiệu (mô hình có độ dài tự nhiên ~250-280 từ).

Điểm then chốt: giới hạn của 30M là **tính nhất quán, không phải năng lực đỉnh**. Đuôi phải của phân bố chứa truyện 9.0-9.5 điểm và best-of-N khai thác trực tiếp được nó; ranh giới này chỉ đo được

nhờ chiến dịch kiểm chứng có hệ thống, và bản thân phương pháp đánh giá (protocol cố định, seed bắt cặp, tự đo nhiều judge, xác nhận ở $n=45$) là một đóng góp độc lập của đồ án.

4.2 Trả lời câu hỏi nghiên cứu

Mô hình 30M đạt $\sim 7.9/10$ theo protocol cuối (best-of-3 đạt 8.55, so với 9.75 của Qwen-4B), sinh truyện trọn vẹn đúng miền ở tốc độ ~ 949 token/giây, nhanh hơn ~ 50 lần với kích thước bằng 1/130. **Trên tác vụ được giới hạn tốt, mô hình siêu nhỏ có thể sánh với mô hình lớn trên các trục quan trọng với chi phí bằng một phần nhỏ**, miễn là phần phương sai còn lại được quản lý tại thời điểm suy luận, và với các giới hạn kích thước được ghi nhận trung thực ở nơi chúng bộc lộ.

4.3 Hướng phát triển (kèm bằng chứng khả thi)

- **Scale pretraining** (hướng chính, trực tiếp từ Giới hạn 1): loss còn trên đường power-law chưa plateau; TF1 còn $\sim 2.6M$ truyện chưa dùng. Một run 60M trên full TF1 với seq 1024 đã được khởi động trong khuôn khổ tiếp theo của đồ án.
- **Distillation ở quy mô pretraining** (trộn hàng triệu token teacher vào corpus, hoặc soft label token-level) thay vì SFT vài trăm truyện đã chứng minh phản tác dụng.
- **RL có quy mô với reward rẻ hơn** (scorer nhanh học từ nhiều nhân hơn hẳn mức ~ 500 đã thất bại, hoặc reward theo luật như slot recall) để vượt nút chặn 15 giây một lần gọi judge.
- **Judge mạnh hơn và n lớn mặc định** cho mọi đánh giá (bài học trực tiếp từ Mục 3.4).

5. Tái lập

Mã nguồn nằm dưới `trieulh/` (tách khỏi web app dùng chung): pipeline dữ liệu và huấn luyện (`prepare_tf1_pretrain.py`, `tf1_pretrain/`, notebook dashboard), chiến dịch alignment (`dpo_train_local.py`, `headroom_probe.py`, `raft_*.py`, `rm_train*.py`, `grpo_train.py`, `distill_gen_corpus.py`) và protocol đánh giá resume-safe (`*_judge_eval.py`). Nhật ký thí nghiệm đầy đủ, nguồn của báo cáo này: `trieulh/docs/experiments/2026-07-08-slm-training-log.md`. Artifact (checkpoint, mô hình HF, GGUF, log số liệu, dữ liệu đánh giá) lưu trên Google Drive. Mô hình cuối: `slm-30m-p2.gguf` (39 MB, q8) kèm `Modelfile-30M-p2`, chạy bằng `ollama create slm-30m-p2 -f Modelfile-30M-p2`.

Tài liệu tham khảo

1. Nadas et al. (2025). *TF1-EN-3M*. arXiv:2504.20605.
2. Kaplan et al. (2020). *Scaling Laws for Neural Language Models*.
3. Hoffmann et al. (2022). *Training Compute-Optimal LLMs (Chinchilla)*.
4. Muennighoff et al. (2023). *Scaling Data-Constrained Language Models*.
5. Rafailov et al. (2023). *Direct Preference Optimization*.
6. Williams (1992). *REINFORCE*.
7. Shao et al. (2024). *DeepSeekMath (GRPO)*.
8. Dong et al. (2023). *RAFT: Reward-rAnked FineTuning*.
9. Hinton et al. (2015). *Distilling the Knowledge in a Neural Network*.
10. Gudibande et al. (2023). *The False Promise of Imitating Proprietary LLMs*.